

TRABALLO FIN DE GRAO
GRAO EN CIENCIA E ENXEÑARÍA DE DATOS

Detección de lesiones del ligamento cruzado anterior en resonancias magnéticas de rodilla mediante aprendizaje profundo

Estudiante: Jacobo Cousillas Taboada

Dirección: Laura Morán Fernández

Daniel Vila de la Cruz

A Coruña, junio de 2026.

Agradecimientos

Gracias a mi familia por el amor y el apoyo incondicional que siempre me habéis dado y que me ha ayudado tanto en mi día a día. A vosotros papá y mamá no hay palabras de agradecimiento que valgan, Paloma y yo no podemos estar más orgullosos de tener unos padres tan maravillosos, sois nuestro mayor referente y ojalá algún nos podamos llegar a parecer a vosotros.

Gracias a mis compañeros que me han ayudado a disfrutar de esta experiencia, en especial a Xaime, en el que he encontrado un amigo para toda la vida y con el que he vivido gran parte de estos últimos años. De esta experiencia me llevo recuerdos y personas que siempre van a tener un hueco en mi corazón.

Gracias a mis tutores Laura y Daniel por vuestra ayuda y el gran tiempo dedicado para lograr llevar a cabo la propuesta de este trabajo de fin de grado.

Resumen

La resonancia magnética de rodilla es la técnica de referencia para el diagnóstico de lesiones del ligamento cruzado anterior (LCA), pero su interpretación está sujeta a una variabilidad inter e intraobservador significativa que puede comprometer la detección de lesiones reales. Este trabajo propone un sistema de detección automática de lesiones del LCA basado en aprendizaje profundo, estructurado en dos fases secuenciales: una primera de triaje general, que identifica los estudios con posibles hallazgos, y una segunda de clasificación específica de la lesión. Cada fase procesa de forma independiente los tres planos estándar de adquisición mediante redes ResNet-18 dotadas de un mecanismo de atención, cuyas salidas se combinan de forma ponderada. Evaluado mediante validación cruzada estratificada de 5 *folds* sobre el conjunto de datos MRNet, el sistema alcanza un AUC de 0,838 y una sensibilidad del 84,7 %. El preprocesamiento de las imágenes, en particular la ecualización adaptativa del contraste (CLAHE), mejora de forma estadísticamente significativa el rendimiento respecto a la versión base. El sistema se complementa, además, con mapas de activación GradCAM++ que aportan interpretabilidad a sus predicciones.

Abstract

Knee magnetic resonance imaging is the reference technique for diagnosing anterior cruciate ligament (ACL) injuries, yet its interpretation is subject to significant inter- and intra-observer variability that may lead to missed pathologies. This work proposes a deep learning system for the automatic detection of ACL injuries, structured in two sequential phases: a first general triage stage that identifies studies with potential findings, and a second stage of specific injury classification. Each phase independently processes the three standard acquisition planes using ResNet-18 networks equipped with an attention mechanism, whose outputs are combined through a weighted scheme. Evaluated through stratified 5-fold cross-validation on the MRNet dataset, the system achieves an AUC of 0.838 and a sensitivity of 84.7 %. Image preprocessing, in particular adaptive contrast equalisation (CLAHE), yields a sta-

tistically significant improvement over the baseline version. The system is further complemented with GradCAM++ activation maps that provide interpretability for its predictions.

Palabras clave:

- Aprendizaje profundo
- Resonancia magnética de rodilla
- Ligamento cruzado anterior
- Diagnóstico asistido por computador
- Redes neuronales convolucionales
- Interpretabilidad
- Conjunto de datos MRNet

Keywords:

- Deep learning
- Knee magnetic resonance imaging
- Anterior cruciate ligament
- Computer-aided diagnosis
- Convolutional neural networks
- Interpretability
- MRNet dataset

Índice general

1	Introducción	1
1.1	Motivación personal	2
1.2	Objetivos	2
1.3	Alcance	3
1.4	Planificación y costes	4
1.5	Herramientas y entorno	4
1.6	Estructura de la memoria	6
2	Estado del arte	7
2.1	Aprendizaje profundo en imagen médica	7
2.2	El conjunto de datos MRNet	8
2.3	Trabajos previos en detección de lesiones del LCA	9
2.3.1	MRNet original (Bien et al., 2018)	10
2.3.2	Redes residuales y aprendizaje por transferencia	10
2.3.3	Enfoques comparativos sobre MRNet	11
2.3.4	Arquitecturas avanzadas	11
2.3.5	Enfoques sobre otros conjuntos de datos	11
2.4	Técnicas de preprocesamiento en RM	12
2.4.1	CLAHE: realce de contraste adaptativo	12
2.4.2	Otras técnicas de normalización	12
2.5	Mecanismos de agregación sobre cortes	13
2.5.1	Max pooling	13
2.5.2	Attention pooling	13
2.6	Técnicas de interpretabilidad	14
2.6.1	GradCAM	14

2.6.2	GradCAM++	14
2.6.3	Interpretabilidad en el contexto volumétrico	15
2.7	Posicionamiento del presente trabajo	15
3	Preparación de datos	16
3.1	Descripción del conjunto de datos	16
3.2	Análisis exploratorio	17
3.2.1	Distribución de cortes por plano	18
3.2.2	Visualización de muestras	18
3.3	Flujo de preprocesamiento	19
3.3.1	Selección y rellenado de cortes	20
3.3.2	Recorte central	20
3.3.3	Redimensionado	20
3.3.4	CLAHE: realce de contraste adaptativo local	21
3.3.5	Normalización	21
3.3.6	Máscara de atención anatómica	22
3.3.7	Aumento de datos	23
3.4	Implementación	24
4	Metodología	25
4.1	Visión general de la arquitectura	25
4.2	<i>Backbone</i> : ResNet-18	26
4.2.1	Adaptación al dominio	26
4.2.2	Evaluación de <i>backbones</i> alternativos	26
4.3	<i>Attention pooling</i> sobre cortes	27
4.4	Fase 1: Detección de anomalías	28
4.4.1	Función de pérdida: <i>Focal Loss</i>	28
4.4.2	Papel de la Fase 1 en el flujo del sistema	29
4.5	Fase 2: Clasificación de LCA y menisco	29
4.5.1	Fusión ponderada por plano	29
4.5.2	Función de pérdida	30
4.6	Regularización	31
4.6.1	Congelamiento de capas	31
4.6.2	Dropout	32
4.6.3	Aumento de datos	32

4.6.4	Parada temprana y planificador de tasa de aprendizaje	32
4.7	Optimización del umbral de decisión	32
4.8	Métricas de evaluación	34
4.9	Procedimiento de entrenamiento	34
5	Resultados	37
5.1	Evolución del sistema	37
5.2	Resultados de la validación cruzada	38
5.3	Evaluación de la fase de triaje	40
5.4	Contribución de cada plano anatómico	41
5.5	Análisis estadístico	43
5.5.1	Intervalos de confianza	43
5.5.2	Validación del impacto de CLAHE	44
5.5.3	Impacto del <i>attention pooling</i>	44
5.5.4	Impacto del aumento de datos	45
5.6	Interpretabilidad	45
5.6.1	Discrepancia entre el corte de atención y el corte central . . .	46
5.6.2	Mapas de activación	46
5.7	Análisis de errores	46
5.8	Reportes clínicos	48
5.9	Eficiencia computacional	48
5.10	Caso de estudio: aplicación a un caso clínico real	48
5.11	Síntesis de resultados	51
6	Conclusiones	53
6.1	Aportaciones del trabajo	53
6.2	Cumplimiento de objetivos	54
6.3	Limitaciones	55
6.4	Líneas futuras de investigación	56
	Bibliografía	58

Índice de figuras

1.1	Diagrama de Gantt con la planificación temporal del proyecto.	5
2.1	Muestras del conjunto de datos MRNet para los tres planos de adquisición. Fila superior: caso con lesión del LCA. Fila inferior: caso sin lesión. De izquierda a derecha: plano sagital, coronal y axial.	9
3.1	Distribución de casos positivos y negativos de cada etiqueta diagnóstica del conjunto de datos MRNet.	17
3.2	Distribución del número de cortes por plano en el conjunto de datos MRNet. La línea roja discontinua indica la mediana de cada plano y la línea negra punteada el valor objetivo de 32 cortes seleccionado para la estandarización.	19
3.3	Efecto de CLAHE y máscara anatómica sobre un corte sagital de RM de rodilla. Izquierda: imagen original. Derecha: imagen tras la aplicación de CLAHE ($clip_limit = 2,0$, $grid_size = 8 \times 8$) y máscara anatómica gaussiana.	22
4.1	Flujo general del sistema propuesto.	26
5.1	Curvas ROC obtenidas en los cinco <i>folds</i> de la validación cruzada. La curva azul representa el comportamiento medio del sistema (AUC 0,838) y el punto destacado corresponde al punto operativo del umbral clínico seleccionado (sensibilidad $\geq 85\%$).	40

5.2	Curvas de pérdida de entrenamiento (línea continua) y validación (línea discontinua) para cada uno de los cinco <i>folds</i> de la validación cruzada, en paneles independientes. Los marcadores verticales indican el punto de detención temprana de cada <i>fold</i>	41
5.3	Mapas de GradCAM++ sobre el corte de máxima atención de cada plano anatómico para un caso del conjunto de test. Columna izquierda: corte original en escala de grises. Columna derecha: mapa de activación superpuesto. Las regiones cálidas (amarillo-rojo) indican las zonas que más contribuyen a la predicción del modelo.	47
5.4	Mapas de GradCAM++ sobre el corte de máxima atención de cada plano para el caso clínico personal (secuencia PD con supresión grasa, centro externo). Las regiones cálidas indican las zonas anatómicas que sustentan la predicción del sistema. La activación en la región intercondílea del plano sagital es coherente con la localización del LCA.	50
5.5	Reporte clínico generado por el sistema para el caso clínico personal. Integra el resultado del triaje (Fase 1), la probabilidad de lesión por patología con su nivel de sospecha (Fase 2), el desglose por plano anatómico y las advertencias sobre cortes de atención en el borde del volumen.	51

Índice de cuadros

1.1	Estimación de costes del proyecto.	5
3.1	Distribución de etiquetas diagnósticas en el conjunto de datos MRNet (1 250 casos).	17
3.2	Estadísticas del número de cortes por plano en el conjunto de datos MRNet.	18
4.1	Pesos de fusión por plano para cada patología.	30
4.2	Hiperparámetros del sistema.	36
5.1	Evolución del AUC medio (validación cruzada de 5 <i>folds</i>) a través de las principales decisiones de diseño que afectan al poder discrimina- tivo del sistema.	38
5.2	Resultados de la validación cruzada de 5 <i>folds</i> para la detección de lesiones del LCA.	39
5.3	Resultados de la Fase 1 (detección de anomalías) por <i>fold</i>	42
5.4	Ablación por plano anatómico para la detección de lesiones del LCA (valores medios de la validación cruzada de 5 <i>folds</i>). Las columnas Sens y Espec se calculan al umbral clínico.	42
5.5	Intervalos de confianza al 95 % de las métricas principales.	44
5.6	Ablación del aumento de datos (<i>fold</i> 1). Sens: sensibilidad; Espec: es- pecificidad; F1: puntuación F1; AUC: área bajo la curva ROC.	45
5.7	Distancia entre el corte de máxima atención y el corte central.	46
5.8	Resultados del sistema sobre el caso clínico personal.	49

Capítulo 1

Introducción

LA resonancia magnética (RM) se ha consolidado como la herramienta de referencia en el diagnóstico de lesiones musculoesqueléticas, especialmente en articulaciones complejas como la rodilla. Su capacidad para diferenciar tejidos blandos sin radiación ionizante la convierte en el estándar clínico para detectar lesiones del ligamento cruzado anterior (LCA), rupturas meniscales y otras patologías estructurales. Las lesiones del LCA presentan una incidencia significativa en la población general, con estudios epidemiológicos que reportan tasas de reconstrucción crecientes en las últimas décadas [1], y una prevalencia especialmente elevada en deportistas jóvenes que practican deportes de contacto o de cambios de dirección.

A pesar de su utilidad diagnóstica, la interpretación de estudios de RM depende críticamente de la experiencia del personal de radiología y está sujeta a variabilidad inter e intraobservador. Revisiones sistemáticas reportan una sensibilidad del 87 % y una especificidad del 93 % para la detección de lesiones del LCA mediante RM [2], lo que implica que aproximadamente un 13 % de las lesiones no son detectadas. Otros trabajos documentan tasas de concordancia entre personal de radiología que oscilan entre el 75 % y el 95 % [3], evidenciando que incluso especialistas experimentados pueden llegar a conclusiones diferentes ante las mismas imágenes. A esta variabilidad contribuye el desgaste cognitivo acumulado durante la jornada laboral: un mismo profesional puede modificar su criterio diagnóstico sobre una misma imagen en función del momento del día y la carga de trabajo acumulada [4]. Una herramienta de asistencia automatizada permite reducir esta fatiga al ofrecer una segunda lectura objetiva y constante, mejorando no solo la detección directa sino también el rendimiento del propio profesional al final de su jornada.

El aprendizaje profundo ha demostrado en los últimos años un rendimiento com-

parable o superior al de especialistas humanos en múltiples tareas de diagnóstico por imagen [5, 6]. En el ámbito de la resonancia magnética de rodilla, Bien et al. [7] introdujeron en 2018 el conjunto de datos MRNet junto con una arquitectura basada en AlexNet [8], preentrenada en ImageNet [9], capaz de detectar anomalías generales, lesiones del LCA y desgarros meniscales con resultados prometedores. Trabajos posteriores como los de Azcona et al. [10] y Panteli et al. [11] han explorado arquitecturas más complejas y enfoques progresivos sobre el mismo conjunto de datos. Sin embargo, la mayoría de estos sistemas comparten dos limitaciones: han sido evaluados sobre particiones fijas de 120 casos [12], y la interpretabilidad de las predicciones ha recibido una atención limitada [13].

1.1 Motivación personal

El interés por desarrollar este proyecto no nace de una simple inquietud académica, sino de una experiencia personal. Durante la práctica deportiva sufrí una lesión grave de rodilla. La primera resonancia magnética dio pie a un informe clínico confuso: se diagnosticó una rotura completa del LCA, combinada con esguinces colaterales y contusiones en el menisco externo. Con la incertidumbre de un diagnóstico tan severo, decidí consultar a otros especialistas; tras revisar las mismas imágenes, concluyeron que la rotura del LCA era solo parcial, lo que cambiaba por completo el enfoque de mi recuperación. La sorpresa real llegó siete meses después: al repetir la RM para evaluar la evolución, descubrí que también tenía el menisco externo roto y que esa lesión había pasado totalmente desapercibida en el análisis inicial.

Vivir este proceso me hizo ver con claridad las limitaciones reales a las que se enfrenta el diagnóstico por imagen tradicional. Comprobé cómo un error o una omisión en la lectura de una resonancia impacta de forma directa en la salud, la psicología y los tiempos de recuperación de la persona afectada. Esta vivencia despertó mi motivación por investigar cómo los modelos computacionales pueden aportar objetividad y reproducibilidad al entorno clínico.

1.2 Objetivos

El objetivo principal de este trabajo es diseñar, implementar y evaluar un sistema de aprendizaje profundo multiplano capaz de procesar volúmenes de resonancia mag-

nética de rodilla para la detección de lesiones del LCA, proporcionando predicciones interpretables y priorizando la detección de lesiones reales mediante la optimización del umbral de decisión para sensibilidad. Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

1. Analizar las características del conjunto de datos empleado y estudiar sus implicaciones sobre el desarrollo del sistema.
2. Diseñar e implementar un sistema basado en aprendizaje profundo para la detección automática de lesiones de rodilla mediante resonancia magnética.
3. Estudiar el impacto de distintas estrategias de preprocesamiento y diseño arquitectónico sobre el rendimiento del sistema.
4. Evaluar experimentalmente el sistema desarrollado utilizando métricas adecuadas al problema planteado y una estrategia de evaluación robusta.
5. Analizar mecanismos que permitan mejorar la interpretabilidad de las predicciones generadas por el modelo.

1.3 Alcance

El proyecto se centra en la detección de lesiones del LCA, sin abordar la segmentación de estructuras anatómicas ni la clasificación de la gravedad de la lesión (parcial frente a completa). Se utiliza exclusivamente el conjunto de datos público MRNet [7], sin incluir datos de otros centros hospitalarios ni protocolos de adquisición diferentes. El sistema se plantea como herramienta de apoyo al proceso diagnóstico, no como sustitución del criterio clínico. El trabajo incorpora aspectos relacionados con la interpretabilidad del modelo además del análisis de su rendimiento predictivo.

Aunque el conjunto de datos MRNet proporciona etiquetas también para desgarros meniscales, y el sistema incorpora la predicción de esta patología como salida secundaria de la Fase 2, la evaluación cuantitativa sistemática mediante validación cruzada se circunscribe a la detección del LCA, en consonancia con el objetivo principal del trabajo. La predicción meniscal se ilustra cualitativamente en el caso clínico personal del Capítulo 5, pero no se reportan métricas de validación cruzada para esta tarea.

1.4 Planificación y costes

A continuación se presenta la planificación temporal del proyecto y una estimación de los costes asociados.

El desarrollo del proyecto se estructura en cinco fases, solapadas en el tiempo según la naturaleza iterativa del trabajo. Su distribución temporal se muestra en la Figura 1.1:

1. **Definición y exploración inicial** (noviembre–diciembre 2025): formulación de la propuesta de proyecto, revisión bibliográfica, búsqueda de un conjunto de datos y análisis del mismo, incluyendo las primeras pruebas de concepto con un modelo de clasificación.
2. **Desarrollo del sistema** (diciembre 2025–marzo 2026): diseño e implementación de un modelo de aprendizaje profundo, evaluando qué configuración es la más adecuada para resolver el problema.
3. **Interpretabilidad y análisis cualitativo** (febrero–mayo 2026): integración de técnicas de explicabilidad visual para la validación clínica, análisis sistemático de errores y evaluación de la viabilidad.
4. **Experimentación y evaluación** (mayo–junio 2026): ejecución de las pruebas con las configuraciones seleccionadas, comparando estadísticas de rendimiento de los modelos candidatos y realizando un análisis de los resultados obtenidos.
5. **Redacción de la memoria** (mayo–junio 2026): elaboración de la documentación, integración de resultados y preparación de la defensa.

Por su parte, el Cuadro 1.1 recoge la estimación de los costes asociados al proyecto. Los salarios se estiman a partir de datos del mercado laboral español para perfiles tecnológicos junior y docentes universitarios [14].

1.5 Herramientas y entorno

En esta sección se describen las principales herramientas de software y el entorno de ejecución empleados durante el desarrollo del proyecto.




Figura 1.1: Diagrama de Gantt con la planificación temporal del proyecto.

Cuadro 1.1: Estimación de costes del proyecto.

Tipo	Recurso	Cantidad / Duración	Coste (€)
Material	Kaggle Notebooks	1	0
Material	Overleaf	1	0
Material	Ordenador portátil	1	900
Material	Electricidad	210 días	315
Material	Conexión a Internet	210 días	210
Personal	Alumno	3 h/día × 210 días = 630 h	8 820
Personal	Tutora	40 h	1 384
Personal	Tutor	40 h	1 384
Coste total del proyecto (€)			13 013

El desarrollo del sistema se realiza íntegramente en Python, empleando las siguientes herramientas principales:

- **PyTorch** [15]: entorno de aprendizaje profundo utilizado para la implementación y entrenamiento del modelo propuesto.
- **OpenCV** [16]: biblioteca de visión por computador empleada para el preprocesamiento de imagen (CLAHE, redimensionado, rotaciones).
- **NumPy y Pandas**: manipulación de datos numéricos y tabulares, carga del conjunto de datos MRNet y gestión de etiquetas.
- **Matplotlib**: generación de figuras, curvas ROC [17], mapas de atención y visualizaciones de GradCAM++.

- **SciPy**: análisis estadístico (tests t pareados, test de Wilcoxon, tamaño del efecto de Cohen [18]).

El entorno de ejecución es **Kaggle Notebooks** con GPU Tesla T4 (16 GB VRAM), sesiones de hasta 12 horas y persistencia de archivos activada.

1.6 Estructura de la memoria

El resto de la presente memoria académica se estructura y organiza de la siguiente manera:

- **Capítulo 2: Estado del arte.** Revisa los trabajos previos en detección de lesiones del LCA, técnicas de preprocesamiento en RM y métodos de interpretabilidad.
- **Capítulo 3: Preparación de datos.** Detalla el análisis exploratorio del conjunto de datos y el flujo de preprocesamiento, incluyendo CLAHE y la máscara de atención anatómica.
- **Capítulo 4: Metodología.** Describe el diseño del sistema en cascada, las decisiones arquitectónicas y la evolución iterativa del modelo.
- **Capítulo 5: Resultados.** Presenta los resultados experimentales, el análisis estadístico, la interpretabilidad y los reportes clínicos.
- **Capítulo 6: Conclusiones.** Sintetiza las aportaciones, las limitaciones y las líneas futuras de investigación.

Capítulo 2

Estado del arte

EN este capítulo se revisan los principales trabajos y técnicas que conforman el contexto científico del proyecto. Se aborda, en primer lugar, el papel del aprendizaje profundo en el análisis de imagen médica. A continuación, se describen los enfoques específicos aplicados a la detección de lesiones de rodilla en resonancia magnética. Por último, se presentan las técnicas de preprocesamiento e interpretabilidad empleadas en trabajos previos sobre detección de lesiones de rodilla en resonancia magnética.

2.1 Aprendizaje profundo en imagen médica

Las redes neuronales convolucionales (*Convolutional Neural Networks*, CNN) han transformado el campo del análisis de imagen médica en la última década. El trabajo de Esteva et al. [5] en clasificación de lesiones cutáneas, donde los autores reportaron métricas de rendimiento comparables a las de dermatólogos certificados en un estudio experimental controlado, y los sistemas de detección de retinopatía diabética [19] son ejemplos representativos de cómo el aprendizaje profundo ha alcanzado capacidades diagnósticas equiparables a las del experto humano en tareas bien definidas.

El éxito de estas arquitecturas se sustenta en tres factores: la capacidad de las CNN para aprender representaciones jerárquicas de características directamente de los datos, sin necesidad de diseñar manualmente extractores de características; la disponibilidad de grandes conjuntos de datos etiquetados; y el aumento de la capacidad computacional mediante GPUs.

En el ámbito específico de la resonancia magnética musculoesquelética, las CNN enfrentan desafíos particulares que las distinguen de otras aplicaciones de imagen

médica:

- **Naturaleza volumétrica:** cada estudio de RM consta de un volumen tridimensional compuesto por un número variable de cortes bidimensionales, lo que requiere estrategias específicas para agregar la información a lo largo de la dimensión axial del volumen.
- **Bajo contraste del tejido blando:** a diferencia de la radiografía convencional, donde el hueso presenta un contraste elevado, las estructuras ligamentosas y meniscales en RM presentan diferencias de intensidad sutiles que pueden dificultar su identificación tanto por el modelo como por el profesional [20].
- **Múltiples planos de adquisición:** los protocolos estándar de RM de rodilla incluyen adquisiciones en los planos sagital, coronal y axial, cada uno con información complementaria sobre las estructuras anatómicas.
- **Necesidad de interpretabilidad:** en el contexto clínico, el radiólogo debe poder justificar sus decisiones diagnósticas. Un modelo que proporcione únicamente una probabilidad sin explicación visual resulta de limitada utilidad práctica [13].

Estas particularidades motivan el diseño de arquitecturas y flujos de preprocesamiento específicos para RM musculoesquelética.

2.2 El conjunto de datos MRNet

MRNet, publicado por Bien et al. en 2018 [7] y recopilado en el Stanford University Medical Center, se ha consolidado como el banco de pruebas de referencia para la detección automatizada de lesiones de rodilla en resonancia magnética. Una revisión sistemática reciente [21] identificó 23 trabajos en este ámbito, de los cuales la mayoría lo emplea como estándar de comparación. Su relevancia reside en la combinación de tres factores poco habituales de forma simultánea en un conjunto público: la disponibilidad de los tres planos de adquisición estándar (sagital, coronal y axial) para cada examen, la presencia de etiquetas para múltiples patologías (anomalía general, lesión del LCA y lesión meniscal), y un tamaño suficiente para el entrenamiento de redes profundas mediante aprendizaje por transferencia.

La Figura 2.1 muestra ejemplos representativos de cortes en cada plano de adquisición, ilustrando las diferencias de perspectiva anatómica y contraste entre vistas.




Figura 2.1: Muestras del conjunto de datos MRNet para los tres planos de adquisición. Fila superior: caso con lesión del LCA. Fila inferior: caso sin lesión. De izquierda a derecha: plano sagital, coronal y axial.

El análisis detallado de la distribución de etiquetas, el desbalance de clases y las características volumétricas del conjunto se presenta en el Capítulo 3, donde se discuten sus implicaciones sobre el diseño del sistema. Los trabajos que han empleado MRNet como banco de pruebas se revisan en la sección siguiente; los enfoques basados en otros conjuntos de datos se describen en la Sección 2.3.5.

2.3 Trabajos previos en detección de lesiones del LCA

A continuación se revisan los principales enfoques propuestos en la literatura para la detección automática de lesiones del LCA en resonancia magnética.

2.3.1 MRNet original (Bien et al., 2018)

El trabajo original de Bien et al. [7] propone una arquitectura basada en AlexNet [8] preentrenada en ImageNet [9], donde cada plano se procesa de forma independiente. Para cada volumen, los cortes se pasan individualmente por la CNN y la predicción a nivel de volumen se obtiene mediante *max pooling* sobre las activaciones de los cortes. La predicción final para cada patología se calcula mediante regresión logística sobre las salidas de los tres modelos por plano.

Los autores reportan un AUC de 0,937 para anomalías, 0,965 para LCA y 0,847 para menisco. Sin embargo, estos resultados presentan limitaciones metodológicas: se obtuvieron sobre una partición fija de validación (120 casos) sin validación cruzada, y el conjunto de test no se ha hecho público, lo que dificulta la comparación directa con trabajos posteriores.

El enfoque de *max pooling* sobre cortes, aunque eficiente, presenta una limitación conceptual relevante: al seleccionar únicamente el corte con mayor activación, se descarta la información contextual de los cortes adyacentes, que pueden contener evidencia complementaria sobre la extensión de la lesión.

2.3.2 Redes residuales y aprendizaje por transferencia

Las redes residuales (*Residual Networks*, ResNet), propuestas por He et al. [22], introdujeron conexiones directas (*skip connections*) entre capas no contiguas que permiten el entrenamiento estable de redes de gran profundidad. A diferencia de las arquitecturas convolucionales clásicas, en las que el gradiente tiende a desvanecerse al retropropagarse por muchas capas, las conexiones residuales lo propagan directamente a capas anteriores, haciendo posible el entrenamiento de arquitecturas de 18, 50 o 101 capas con resultados competitivos en tareas de reconocimiento visual.

En el contexto del análisis de imagen médica, las ResNet preentrenadas en ImageNet [9] han demostrado ser transferibles a dominios visuales distintos del fotográfico. Yosinski et al. [23] mostraron que las capas iniciales de una red convolucional aprenden detectores de características genéricos (bordes, texturas, patrones de color) aplicables a dominios muy diferentes del de entrenamiento, mientras que las capas más profundas aprenden representaciones específicas de la tarea concreta. Litjens et al. [6] confirmaron, en una revisión sistemática sobre aprendizaje profundo en imagen médica, que el aprendizaje por transferencia desde ImageNet proporciona una inicia-

lización efectiva incluso con conjuntos de datos reducidos, y que ResNet constituye una de las arquitecturas más empleadas en este dominio.

2.3.3 Enfoques comparativos sobre MRNet

Trabajos posteriores han abordado la clasificación de lesiones de rodilla desde distintas perspectivas. Azcona et al. [10] realizaron un estudio comparativo de técnicas de aprendizaje profundo sobre MRNet, evaluando el rendimiento de aprendizaje por transferencia con diversas arquitecturas (ResNet, VGG [24] y AlexNet) tanto entrenadas desde cero como preentrenadas en ImageNet. Sus resultados, con un AUC de 0,934 para la detección de anomalías, confirman que el aprendizaje por transferencia desde ImageNet es efectivo incluso cuando el dominio de origen difiere sustancialmente del de destino. Su principal limitación es la asignación de pesos iguales a todos los planos en la fusión, ignorando la evidencia radiológica que indica que el plano sagital es más informativo para la evaluación del LCA.

Por su parte, Panteli et al. [11] propusieron un enfoque progresivo sobre MRNet, demostrando que la aplicación secuencial de técnicas de preprocesamiento y aumento de datos mejora de forma incremental el rendimiento de los modelos.

2.3.4 Arquitecturas avanzadas

Trabajos más recientes han explorado arquitecturas de mayor complejidad, incorporando mecanismos de atención visual para ponderar las regiones más relevantes de cada corte, extracción de características multi-escala y fusión de características a nivel intermedio (*feature-level fusion*) en vez de a nivel de decisión. Algunos de estos enfoques reportan AUCs superiores a 0,95 para la detección de lesiones del LCA [25]. Sin embargo, el incremento en la complejidad estructural conlleva un coste computacional significativamente mayor y, con frecuencia, una reducción en la interpretabilidad del modelo, lo que puede limitar su adopción en entornos clínicos [20].

2.3.5 Enfoques sobre otros conjuntos de datos

Aunque MRNet es el banco de pruebas dominante, una parte de la literatura ha abordado la detección de lesiones de rodilla sobre conjuntos institucionales propios. Wang et al. [26] desarrollaron un sistema que combina detección de objetos mediante

YOLOv9 y redes convolucionales sobre un conjunto de 253 pacientes con RM sagital, alcanzando resultados competitivos mediante un enfoque de detección y clasificación en dos etapas. La revisión sistemática [21] documenta otros trabajos con datos propietarios que, aunque menos comparables entre sí por la heterogeneidad de protocolos y criterios de etiquetado, evidencian que el problema no se circunscribe a un único centro ni a un único protocolo de adquisición.

La dependencia de la comunidad en MRNet como estándar de facto facilita la comparación directa entre métodos, pero plantea dudas sobre la capacidad de generalización de los modelos a otros centros hospitalarios con equipos y secuencias distintos, cuestión que permanece en gran medida abierta en la literatura [20].

2.4 Técnicas de preprocesamiento en RM

El preprocesamiento de imágenes de resonancia magnética desempeña un papel fundamental en el rendimiento de los sistemas de clasificación basados en aprendizaje profundo [6]. A diferencia de la fotografía natural, donde los modelos preentrenados en ImageNet pueden aplicarse con modificaciones mínimas, las imágenes de RM presentan artefactos y características específicas que requieren tratamiento previo.

2.4.1 CLAHE: realce de contraste adaptativo

CLAHE (*Contrast Limited Adaptive Histogram Equalization*), propuesta por Pizer et al. [27], es una técnica de realce de contraste que opera de forma local sobre regiones de la imagen. A diferencia de la ecualización global del histograma, evita la saturación de zonas de alto contraste adaptándose a las variaciones de intensidad locales.

Esta técnica resulta particularmente relevante para imagen de RM musculoesquelética, donde las estructuras ligamentosas y meniscales presentan un contraste bajo respecto al hueso cortical y al líquido sinovial circundante. Su eficacia como etapa de preprocesamiento previa al entrenamiento de redes convolucionales en imagen médica ha sido documentada en la literatura [6].

2.4.2 Otras técnicas de normalización

Además de CLAHE, la literatura recoge diversas técnicas de normalización de intensidad aplicadas a imagen de RM, entre las que destacan la corrección del campo

de sesgo, la normalización Z-score y la igualación de histogramas entre sujetos [6]. La elección entre ellas depende del objetivo concreto: algunas están orientadas a reducir la variabilidad entre centros, mientras que otras actúan como regularizadores implícitos durante el entrenamiento.

2.5 Mecanismos de agregación sobre cortes

Un desafío fundamental en el procesamiento de volúmenes de RM con redes 2D es la agregación de las predicciones individuales de cada corte en una predicción a nivel de volumen.

2.5.1 Max pooling

El enfoque más simple y ampliamente utilizado, adoptado en el MRNet original [7], consiste en procesar cada corte de forma independiente y seleccionar la activación máxima:

$$\mathbf{o} = \max_{s=1}^S f_{\theta}(\mathbf{x}_s) \quad (2.1)$$

donde f_{θ} es la red convolucional, $\mathbf{x}_s$ es el corte s -ésimo y S es el número total de cortes. Esta estrategia tiene la ventaja de su simplicidad computacional, pero presenta una limitación conceptual importante descrita en la literatura: toda la predicción del volumen depende de un único corte. Como consecuencia, los cortes adyacentes, que pueden contener información complementaria sobre la extensión y naturaleza de la lesión, quedan completamente ignorados.

2.5.2 Attention pooling

Los mecanismos de atención permiten que el modelo aprenda a asignar un peso a cada corte en función de su relevancia para la tarea de clasificación. En lugar de seleccionar un único corte ganador, la predicción se calcula como la media ponderada de las activaciones de todos los cortes:

$$\alpha_s = \frac{\exp(g(\mathbf{h}_s))}{\sum_{j=1}^S \exp(g(\mathbf{h}_j))}, \quad \mathbf{o} = \sum_{s=1}^S \alpha_s \cdot \mathbf{h}_s \quad (2.2)$$

donde $\mathbf{h}_s = f_\theta(\mathbf{x}_s)$ son las características extraídas del corte s , g es una red de atención (típicamente un perceptrón multicapa pequeño) y α_s son los pesos de atención normalizados mediante la función softmax.

Ilse et al. [28], que formalizan este mecanismo en el contexto del aprendizaje de múltiple instancia, señalan dos ventajas principales respecto al *max pooling*. En primer lugar, la agregación ponderada permite combinar información de múltiples cortes, capturando la extensión espacial de la lesión en lugar de depender de un único corte. En segundo lugar, los pesos de atención α_s constituyen en sí mismos un mapa de interpretabilidad que indica qué cortes el modelo considera más informativos para su predicción.

2.6 Técnicas de interpretabilidad

La interpretabilidad de los modelos de aprendizaje profundo es un requisito fundamental para su adopción clínica [13]. Un modelo que proporcione únicamente una probabilidad de lesión sin indicar las regiones o los cortes que fundamentan esa predicción resulta de limitada utilidad en entornos médicos, donde el profesional necesita validar la sugerencia del sistema con su propio criterio diagnóstico.

2.6.1 GradCAM

Gradient-weighted Class Activation Mapping (GradCAM), propuesto por Selvaraju et al. [29], genera mapas de calor que indican las regiones de la imagen que más contribuyen a la predicción del modelo para una clase determinada. El método pondera los mapas de activación de la última capa convolucional mediante los gradientes de la predicción respecto a dichas activaciones, produciendo una localización visual de las regiones relevantes.

2.6.2 GradCAM++

GradCAM++, propuesto por Chattopadhyay et al. [30], extiende GradCAM mediante una ponderación posición-dependiente de los gradientes que permite localizaciones más precisas, especialmente cuando múltiples instancias de la misma clase aparecen en la imagen o cuando las lesiones ocupan una fracción pequeña de esta.

2.6.3 Interpretabilidad en el contexto volumétrico

La aplicación de métodos basados en mapas de activación (como GradCAM o GradCAM++) en el contexto específico de volúmenes de RM plantea un desafío metodológico: la elección del corte sobre el cual aplicar la visualización. La práctica habitual en los trabajos que emplean redes 2D, incluyendo el diseño original de Bien et al. [7], ha consistido en visualizar el corte geoméricamente central del volumen bajo la asunción de que representa el núcleo de la estructura anatómica. Singh et al. [13] advierten, en su revisión sobre interpretabilidad en aprendizaje profundo médico, que la selección ad hoc del corte de visualización puede comprometer la fidelidad de la explicación generada, ya que el corte efectivamente utilizado por el modelo en su predicción puede no coincidir con el elegido por convención.

2.7 Posicionamiento del presente trabajo

Este trabajo se sitúa en la intersección de las líneas de investigación descritas, identificando cuatro limitaciones recurrentes en la literatura que orientan las decisiones de diseño del sistema propuesto.

En primer lugar, los trabajos revisados adoptan mayoritariamente fusiones con pesos uniformes entre planos [10], sin reflejar la distinta relevancia diagnóstica de cada vista para patologías específicas. En segundo lugar, el empleo generalizado de *max pooling* para la agregación de cortes [7] descarta la información contextual de los cortes adyacentes, limitando la capacidad del modelo para capturar la continuidad espacial de la lesión. En tercer lugar, la evaluación sobre particiones fijas de tamaño reducido [7, 10] limita la robustez estadística de las métricas reportadas. Por último, la interpretabilidad de las predicciones ha recibido una atención limitada en los sistemas existentes [13], lo que dificulta la validación clínica de las salidas del modelo. El sistema propuesto aborda cada una de estas brechas; las decisiones de diseño concretas se describen en el Capítulo 4.

Preparación y análisis de datos

EL presente capítulo detalla el proceso de exploración, análisis y preprocesamiento del conjunto de datos MRNet empleado en este trabajo. Se documenta el análisis exploratorio que justifica las decisiones de diseño del flujo de preprocesamiento, se describe cada etapa aplicada y se presenta el estudio de ablación realizado para evaluar el impacto del aumento de datos.

3.1 Descripción del conjunto de datos

Como se introdujo en el Capítulo 2, el conjunto de datos MRNet v1.0 fue publicado por el Stanford ML Group en 2018 [7] y contiene estudios de resonancia magnética de rodilla del Stanford University Medical Center. Para el presente trabajo se unifican los conjuntos de entrenamiento (1 130 casos) y validación (120 casos) originales, obteniendo un total de 1 250 casos disponibles¹.

Cada caso consta de tres volúmenes correspondientes a los planos de adquisición sagital, coronal y axial. Los volúmenes se almacenan como matrices *NumPy* de tipo *uint8* con resolución de 256×256 píxeles por corte y rango de valores entre 0 y 255. El número de cortes varía entre casos y entre planos dentro de un mismo caso, reflejando las diferencias en los protocolos de adquisición empleados a lo largo del periodo de recopilación (2001–2012).

Las etiquetas diagnósticas son binarias e independientes entre sí: un mismo caso puede presentar anomalía general, lesión del LCA y lesión meniscal simultáneamente. El Cuadro 3.1 muestra la distribución de etiquetas en el conjunto de datos completo.

¹ El conjunto de test original (120 casos) no es público y por tanto no se utiliza.

Cuadro 3.1: Distribución de etiquetas diagnósticas en el conjunto de datos MRNet (1 250 casos).

Patología	Positivos	Negativos	Prevalencia
Anomalía general	1 008	242	80,6 %
Lesión del LCA	262	988	21,0 %
Lesión meniscal	449	801	35,9 %

El desbalanceo es especialmente relevante para la etiqueta del LCA, donde la clase positiva representa solo el 21,0 % de los casos (ratio aproximado 1:4). Un clasificador trivial que predijera siempre la clase mayoritaria (negativo) alcanzaría una precisión del 79 %, lo que subraya la necesidad de emplear métricas de evaluación apropiadas como la sensibilidad, la especificidad y el AUC.

La Figura 3.1 visualiza esta distribución, donde se aprecia claramente el desbalanceo en las tres etiquetas, siendo la del LCA la más acusada.




Figura 3.1: Distribución de casos positivos y negativos de cada etiqueta diagnóstica del conjunto de datos MRNet.

3.2 Análisis exploratorio

Se realiza un análisis exploratorio exhaustivo del conjunto de datos con el doble objetivo de comprender sus características y justificar las decisiones de preprocesamiento.

3.2.1 Distribución de cortes por plano

El número de cortes por volumen varía considerablemente entre casos y entre planos. El Cuadro 3.2 resume las estadísticas descriptivas.

Cuadro 3.2: Estadísticas del número de cortes por plano en el conjunto de datos MR-Net.

Plano	Mínimo	Máximo	Media	Mediana
Sagital	17	51	30,4	30
Coronal	17	58	29,7	30
Axial	19	61	34,3	35

La Figura 3.2 muestra los histogramas de distribución de cortes para cada plano, con la mediana y el valor objetivo de 32 cortes marcados como referencia. En ella puede apreciarse que la mediana se sitúa en 30 cortes en los planos sagital y coronal y en 35 en el axial. Sin embargo, la dispersión en torno a esos valores es considerable: hay estudios que superan los 50 cortes por plano, prácticamente el doble de la mediana, mientras que otros apenas alcanzan la mitad, con mínimos de entre 17 y 19 cortes. Esta disparidad en el número de imágenes por volumen hace inviable procesar los casos directamente con una dimensión común y motiva la estandarización a un número fijo de cortes.

Dicho valor objetivo es el número de cortes al que se estandarizan todos los volúmenes para poder procesarlos por lotes con una dimensión común. Se fijó en 32 por situarse muy próximo a la mediana de los tres planos (30 en sagital y coronal, 35 en axial), lo que minimiza la cantidad de información que es necesario recortar en los volúmenes con más cortes o rellenar en los que tienen menos. Además, al ser una potencia de dos, resulta cómodo para las operaciones internas de la red.

La estrategia concreta de selección y rellenado empleada para alcanzar esa dimensión común se detalla en la Sección 3.3.1.

3.2.2 Visualización de muestras

Como ilustra la Figura 2.1 del Capítulo 2, cada caso incluye cortes representativos en los tres planos de adquisición. El plano sagital (vista lateral) es el que mejor




Figura 3.2: Distribución del número de cortes por plano en el conjunto de datos MR-Net. La línea roja discontinua indica la mediana de cada plano y la línea negra punteada el valor objetivo de 32 cortes seleccionado para la estandarización.

permite visualizar el trayecto completo del ligamento cruzado anterior, mostrando su inserción en el fémur y la tibia. El plano coronal (vista frontal) expone la superficie de la meseta tibial y los meniscos, mientras que el plano axial (vista superior) ofrece una perspectiva transversal de la articulación. Al tratarse de una estructura tridimensional, el análisis multiplanar es imprescindible para una evaluación diagnóstica completa [2].

Todas las imágenes son monocanal (escala de grises), lo que requiere adaptar la primera capa convolucional del *backbone* ResNet-18 [22], originalmente diseñada para imágenes RGB de 3 canales, a una entrada de 1 canal.

3.3 Flujo de preprocesamiento

El flujo de preprocesamiento se aplica en un orden específico, donde cada etapa se justifica por las observaciones del análisis exploratorio y por la evidencia de la literatura. Las etapas, en orden de aplicación, son:

1. Selección o rellenado de cortes
2. Recorte central
3. Redimensionado a 224×224
4. CLAHE
5. Normalización min-max
6. Máscara de atención anatómica (solo plano sagital)

7. Aumento de datos (solo en entrenamiento)

3.3.1 Selección y rellenado de cortes

Para estandarizar la dimensión de cortes a 32, se aplican dos estrategias complementarias:

- **Volúmenes con más de 32 cortes:** se seleccionan los 32 cortes centrales, descartando los extremos del volumen que típicamente contienen información de menor relevancia anatómica.
- **Volúmenes con menos de 32 cortes:** se rellenan simétricamente mediante replicación de bordes (*edge padding*), donde el primer y último corte se replican las veces necesarias para alcanzar los 32 cortes objetivo.

3.3.2 Recorte central

Se aplica un recorte central suave que elimina el 2,5 % de cada borde de la imagen, conservando el 95 % central. Este recorte tiene como objetivo eliminar los artefactos de borde producidos por la bobina de RM, que se manifiestan como variaciones de intensidad en la periferia de la imagen y que pueden confundir al modelo durante el entrenamiento.

La elección de un factor de recorte del 95 % responde a la observación empírica de que valores más agresivos pueden eliminar información clínicamente relevante cuando el LCA no se encuentra centrado geométricamente en la imagen.

3.3.3 Redimensionado

Tras el recorte, las imágenes resultantes se redimensionan a 224×224 píxeles mediante interpolación bilineal. Esta resolución coincide con la entrada nativa de ResNet-18 preentrenada en ImageNet [9] y conserva un mayor nivel de detalle anatómico que la alternativa de 128×128 , al tiempo que permite mantener tamaños de lote razonables dentro de las limitaciones de memoria de la GPU disponible. La resolución original de 256×256 píxeles resultó excesiva en términos de coste computacional, impidiendo procesar más de un caso por lote en el entorno de ejecución utilizado.

3.3.4 CLAHE: realce de contraste adaptativo local

Se aplica CLAHE [27] (descrito en la Sección 2.4.1) a cada corte de cada volumen, empleando los siguientes parámetros:

- **Límite de recorte** (*clip limit*) = 2,0: controla la amplificación máxima del contraste. Valores superiores pueden amplificar excesivamente el ruido, mientras que valores inferiores reducen el efecto de realce.
- **Tamaño de rejilla** (*grid size*) = 8×8 : define el número de bloques en los que se divide la imagen para la ecualización local. Una cuadrícula de 8×8 proporciona un balance adecuado entre localidad del realce y suavidad de las transiciones entre bloques.

La implementación se realiza mediante la función `cv2.createCLAHE` de OpenCV [16], aplicada sobre cada corte convertido a tipo `uint8`. El resultado se normaliza de vuelta al rango $[0, 1]$ antes de continuar con las siguientes etapas.

La Figura 3.3 ilustra el efecto de CLAHE sobre un corte sagital del conjunto de datos MRNet. La imagen original presenta un pico pronunciado de intensidades en valores bajos, mientras que tras CLAHE la distribución se expande cubriendo un rango más amplio, lo que se traduce en una mayor visibilidad de los bordes internos del tejido blando.

La contribución de CLAHE al rendimiento del modelo se valida experimentalmente mediante un estudio de ablación con análisis de significancia estadística (véase el Capítulo 5).

3.3.5 Normalización

Tras la aplicación de CLAHE, y antes del enmascaramiento anatómico, cada volumen se normaliza individualmente al rango $[0, 1]$ mediante normalización min-max:

$$I_{norm} = \frac{I - I_{min}}{I_{max} - I_{min} + \epsilon} \quad (3.1)$$

donde $\epsilon = 10^{-8}$ evita la división por cero en volúmenes con rango de intensidad nulo. La normalización se aplica por volumen (no por corte) para preservar las relaciones de intensidad entre cortes adyacentes, que pueden ser informativas para la detección de lesiones.




Figura 3.3: Efecto de CLAHE y máscara anatómica sobre un corte sagital de RM de rodilla. Izquierda: imagen original. Derecha: imagen tras la aplicación de CLAHE ($clip_limit = 2,0$, $grid_size = 8 \times 8$) y máscara anatómica gaussiana.

3.3.6 Máscara de atención anatómica

Una vez normalizado el volumen, se aplica una máscara de atención espacial en forma de gaussiana bidimensional que pondera las regiones de la imagen según su relevancia anatómica para la detección del LCA. La máscara se aplica exclusivamente al plano sagital, donde la localización del LCA es anatómicamente predecible: la región intercondílea, ligeramente por encima del centro vertical de la imagen.

La máscara se define formalmente como:

$$M(y, x) = (1 - w_{min}) \cdot \exp \left(-\frac{(y - c_y)^2}{2\sigma_y^2} - \frac{(x - c_x)^2}{2\sigma_x^2} \right) + w_{min} \quad (3.2)$$

donde $(c_y, c_x) = (0,40; 0,50)$ es el centro de la gaussiana en coordenadas normalizadas, $(\sigma_y, \sigma_x) = (0,30; 0,35)$ controlan la dispersión vertical y horizontal, y $w_{min} = 0,3$ es el peso mínimo aplicado en los bordes de la imagen.

La elección de $c_y = 0,40$ (ligeramente por encima del centro vertical) responde a la localización anatómica del LCA en la muesca intercondílea. La dispersión se

configura con valores relativamente amplios para evitar un recorte excesivo de la periferia. El peso mínimo $w_{min} = 0,3$ garantiza que ninguna región de la imagen queda completamente ignorada, preservando la capacidad del modelo de detectar hallazgos inesperados fuera de la zona de interés principal.

La máscara no se aplica a los planos coronal y axial, ya que la localización del LCA difiere sustancialmente en estos planos y una máscara fija podría eliminar información relevante en lugar de potenciarla. El plano coronal es especialmente relevante para la detección de lesiones meniscales, cuya localización anatómica no coincide con la región intercondílea centrada por la máscara. En el plano axial, la localización del LCA presenta mayor variabilidad en esta perspectiva, por lo que la aplicación de una máscara fija tampoco resulta adecuada.

3.3.7 Aumento de datos

Durante el entrenamiento se aplican transformaciones aleatorias a cada volumen con el objetivo de incrementar la variabilidad del conjunto de entrenamiento y reducir el sobreajuste [31]. Las transformaciones se dividen en dos grupos: geométricas y de intensidad.

Las transformaciones geométricas simulan variaciones en la posición del paciente y el protocolo de adquisición:

- **Rotación aleatoria** ($\pm 8^\circ$, prob. 0,5): simula variaciones menores en la orientación del paciente durante la adquisición. Se emplea un ángulo moderado para no distorsionar la anatomía de forma irrealista.
- **Zoom aleatorio** ($\pm 10\%$, prob. 0,5): simula variaciones en el campo de visión del escáner. Si el factor de escala es mayor que 1, se realiza un recorte central del resultado; si es menor, se rellena con replicación de bordes.

Las transformaciones de intensidad simulan variaciones en las condiciones de adquisición de la señal de RM:

- **Ajuste de brillo**: la intensidad de cada píxel se transforma según $I' = \alpha I + \beta$, con $\alpha \sim \mathcal{U}(0,9; 1,1)$ y $\beta \sim \mathcal{U}(-0,05; 0,05)$. Probabilidad de aplicación: 0,5.
- **Ruido gaussiano** ($\sigma = 0,01$, prob. 0,5): añade ruido de baja amplitud que actúa como regularizador.

- **Desenfoco gaussiano** ($\sigma \sim \mathcal{U}(0,3; 0,7)$, prob. 0,7): simula variaciones en la calidad de adquisición y actúa como regularizador adicional.
- **Corrección gamma** ($\gamma \sim \mathcal{U}(0,8; 1,2)$, prob. 0,5): varía el contraste de forma no lineal mediante $I' = I^\gamma$, complementando el ajuste de brillo lineal.

Se descartaron otras transformaciones habituales en visión por computador por razones anatómicas. El volteo horizontal no se aplica porque la orientación de la rodilla (izquierda frente a derecha) es anatómicamente relevante y su inversión produciría imágenes incorrectas. Las deformaciones elásticas se descartaron por el riesgo de distorsionar estructuras anatómicas finas como el LCA, cuya apariencia visual depende críticamente de su forma y continuidad. La evaluación cuantitativa del impacto del aumento de datos se presenta en la Sección 5.5.4 del Capítulo 5.

3.4 Implementación

El flujo de preprocesamiento descrito se implementa como una clase *MRNetDataset* que hereda de *torch.utils.data.Dataset*, siguiendo las convenciones de PyTorch [15] para la carga eficiente de datos. La clase encapsula todas las etapas del flujo y permite configurar la activación del aumento de datos mediante un parámetro booleano, lo que facilita la diferenciación entre el comportamiento de entrenamiento y evaluación.

La máscara anatómica se precalcula en el constructor de la clase y se almacena como un atributo, evitando su recomputación en cada acceso a un ejemplo. El objeto CLAHE de OpenCV se instancia una única vez por llamada al método de carga, minimizando la sobrecarga computacional. El preprocesamiento se aplica durante la carga de cada ejemplo, lo que evita la necesidad de almacenar los datos preprocesados en disco y permite que el aumento de datos genere variaciones diferentes en cada época de entrenamiento.

Capítulo 4

Metodología

ESTE capítulo describe en detalle la arquitectura del sistema propuesto, las decisiones de diseño adoptadas y el procedimiento de entrenamiento y evaluación. El desarrollo del sistema siguió un enfoque iterativo; en este capítulo se presenta la arquitectura final resultante de dicho proceso, justificando cada componente a partir de las limitaciones identificadas durante el desarrollo.

4.1 Visión general de la arquitectura

El sistema propuesto se estructura en dos fases secuenciales que reflejan el flujo de trabajo de un radiólogo ante un estudio de RM de rodilla:

1. **Fase 1 (Triage):** un detector binario de anomalías generales que determina si la rodilla presenta algún hallazgo patológico. Esta fase actúa como filtro inicial, identificando los casos claramente normales, y proporciona además una salida interpretable para los reportes clínicos.
2. **Fase 2 (Clasificación):** un clasificador multitarea que detecta de forma simultánea lesiones del ligamento cruzado anterior y alteraciones meniscales, combinando la información de los tres planos anatómicos mediante fusión ponderada.

Cada fase emplea tres redes ResNet-18 [22] independientes, una por plano anatómico (sagital, coronal, axial), para un total de seis modelos en el sistema completo. La Figura 4.1 resume de forma esquemática el flujo completo, desde la entrada de los volúmenes preprocesados hasta la generación de los reportes clínicos.




Figura 4.1: Flujo general del sistema propuesto.

4.2 Backbone: ResNet-18

Como *backbone* de cada rama del sistema se emplea ResNet-18 [22], preentrenada en ImageNet [9]. La justificación de esta elección se detalló en el estado del arte (Sección 2.3.2); en esta sección se describe su adaptación concreta al dominio de la RM y los resultados de la comparativa con arquitecturas alternativas.

4.2.1 Adaptación al dominio

La ResNet-18 original está diseñada para imágenes RGB de 3 canales. Para adaptarla a las imágenes monocanal de RM, se sustituye la primera capa convolucional (*conv1*) por una nueva capa con 1 canal de entrada en lugar de 3, manteniendo el resto de la arquitectura (64 filtros de 7×7 , *stride* 2, *padding* 3). Los pesos de la nueva *conv1* se inicializan aleatoriamente, mientras que el resto de la red conserva los pesos preentrenados en ImageNet.

La capa de clasificación original (*fc*) de 1 000 clases se sustituye por una secuencia de Dropout [32] (0,5) seguido de una capa lineal que produce el número de salidas requerido: 1 para la Fase 1 (anomalía) y 2 para la Fase 2 (LCA y menisco).

4.2.2 Evaluación de *backbones* alternativos

Para verificar que ResNet-18 es la opción más adecuada dentro de las restricciones computacionales del entorno (GPU Tesla T4, 16 GB VRAM, sesiones de máximo 12 horas), se evaluaron dos *backbones* alternativos:

- **ResNet-50:** con 23,5 millones de parámetros por modelo (141 millones en total para las seis redes), esta arquitectura excedía las limitaciones de memoria y tiempo de la GPU Tesla T4 empleada en el desarrollo. Una ejecución complementaria realizada en un equipo con GPU de mayor capacidad confirmó que ResNet-50 no mejora el rendimiento del sistema, lo que indica que el cuello de botella no está en la capacidad del *backbone* sino en el tamaño limitado del conjunto de datos.

- **EfficientNet-B0 [33]**: a pesar de tener menos parámetros que ResNet-18 (5,3 millones por modelo), esta arquitectura presentaba una convergencia significativamente más lenta. Tras agotar el tiempo máximo de sesión, la pérdida de validación apenas había progresado, mientras que ResNet-18 alcanzaba valores comparables en una fracción de ese tiempo. Esta lentitud se atribuye a las operaciones de convolución *depthwise separable* y los bloques *squeeze-and-excitation*, que aunque son eficientes en parámetros, resultan más lentos en la propagación directa cuando se procesan 6 modelos simultáneamente con 32 cortes por volumen.

En conjunto, estas observaciones llevan a adoptar ResNet-18 por ofrecer el mejor compromiso entre capacidad representativa, velocidad de entrenamiento y compatibilidad con las restricciones computacionales del entorno.

4.3 *Attention pooling sobre cortes*

Cada volumen de RM consta de 32 cortes (tras la estandarización descrita en el Capítulo 3). Para obtener una predicción a nivel de volumen a partir de las predicciones individuales de cada corte, es necesario un mecanismo de agregación. La estrategia más simple consiste en aplicar *max pooling*, seleccionando la activación máxima entre los 32 cortes. Este enfoque, adoptado también en el trabajo original de Bien et al. [7], presenta una limitación fundamental: toda la predicción del volumen depende de un único corte, descartando la información de los cortes adyacentes que pueden contener evidencia complementaria sobre la extensión y naturaleza de la lesión.

Para superar esta limitación, se implementa un módulo de *attention pooling* que aprende a asignar un peso a cada corte en función de su relevancia para la tarea de clasificación. El módulo se define como:

$$\alpha_s = \frac{\exp(g(\mathbf{h}_s))}{\sum_{j=1}^S \exp(g(\mathbf{h}_j))}, \quad \mathbf{o} = \sum_{s=1}^S \alpha_s \cdot \mathbf{h}_s \quad (4.1)$$

donde $\mathbf{h}_s \in \mathbb{R}^d$ es el vector de características producido por la ResNet-18 para el corte s (con d igual al número de salidas de la capa fc : 1 para Fase 1, 2 para Fase 2), y g es una red de atención implementada como un perceptrón multicapa de dos capas:

$$g(\mathbf{h}) = \mathbf{w}_2^T \cdot \tanh(\mathbf{W}_1 \mathbf{h} + \mathbf{b}_1) + b_2 \quad (4.2)$$

con $\mathbf{W}_1 \in \mathbb{R}^{64 \times d}$ y $\mathbf{w}_2 \in \mathbb{R}^{64}$. La función $\tanh$ introduce no linealidad y la normalización *softmax* garantiza que los pesos α_s sumen 1.

El módulo de atención añade únicamente 257 parámetros por rama en la Fase 2 (menos del 0,01 % del total), un coste negligible que se justifica por dos ventajas:

- **Combinación de información volumétrica:** el modelo puede integrar evidencia de múltiples cortes, lo que es especialmente relevante dado que una rotura del LCA es visible típicamente en 3 a 5 cortes consecutivos.
- **Interpretabilidad:** los pesos de atención α_s proporcionan un mapa que indica qué cortes el modelo considera más informativos. Este mapa se utiliza para seleccionar el corte sobre el que se aplica GradCAM++ y constituye en sí mismo una herramienta de interpretabilidad para el radiólogo.

4.4 Fase 1: Detección de anomalías

La Fase 1 del sistema procesa los tres planos de forma independiente mediante tres redes ResNet-18 con *attention pooling*, y fusiona las predicciones por promedio simple de los *logits*:

$$\hat{y}_{anom} = \frac{1}{3} (o_{sag} + o_{cor} + o_{axi}) \quad (4.3)$$

donde o_{sag} , o_{cor} y o_{axi} son las salidas de las tres ramas tras el *attention pooling*. Se emplea promedio simple (pesos iguales) porque la etiqueta de anomalía es genérica y no se asocia a un plano anatómico específico.

4.4.1 Función de pérdida: *Focal Loss*

La Fase 1 se entrena con *Focal Loss* [34], diseñada para abordar el desbalance de clases mediante la reducción de la contribución de los ejemplos bien clasificados:

$$\mathcal{L}_{FL} = -\alpha_t (1 - p_t)^\gamma \log(p_t) \quad (4.4)$$

donde p_t es la probabilidad predicha para la clase correcta, $\alpha = 0,25$ controla el peso relativo de las clases y $\gamma = 2,0$ reduce la contribución de los ejemplos fáciles. Aunque la etiqueta de anomalía presenta un desbalance inverso al del LCA (80,6 % de

positivos), *Focal Loss* resulta efectiva porque reduce el sobreajuste del modelo a los ejemplos fáciles de la clase mayoritaria, forzándolo a aprender las características más sutiles de las rodillas sanas (clase minoritaria).

4.4.2 Papel de la Fase 1 en el flujo del sistema

Además de su función de clasificación, la Fase 1 desempeña un papel estructural dentro del flujo del sistema. Como etapa de triaje, permite informar al radiólogo de si la rodilla presenta signos de anomalía antes de mostrar el análisis específico del LCA, siguiendo el flujo clínico natural. Asimismo, los casos clasificados con seguridad como normales pueden filtrarse antes de la clasificación específica, reduciendo la carga computacional de la Fase 2. Por último, la Fase 1 aporta una capa adicional de confianza a los reportes clínicos: un caso señalado como anómalo por la Fase 1 y con alta probabilidad de lesión por la Fase 2 transmite mayor certeza que un caso con señales contradictorias entre ambas fases.

4.5 Fase 2: Clasificación de LCA y menisco

La Fase 2 constituye el núcleo del sistema de detección de lesiones. Emplea tres redes ResNet-18 independientes (una por plano), cada una con 2 salidas correspondientes a las probabilidades de lesión del LCA y meniscal. Las predicciones de los tres planos se combinan mediante fusión ponderada en espacio de probabilidades.

4.5.1 Fusión ponderada por plano

A diferencia de enfoques previos que emplean pesos iguales para todos los planos [10] o fusionan en espacio de *logits*, el sistema propuesto realiza la fusión en espacio de probabilidades con pesos anatómicamente justificados:

$$P_{LCA} = w_{sag} \cdot \sigma(o_{sag}^{LCA}) + w_{cor} \cdot \sigma(o_{cor}^{LCA}) + w_{axi} \cdot \sigma(o_{axi}^{LCA}) \quad (4.5)$$

donde σ es la función sigmoide y los pesos se fijan en:

La asignación de pesos refleja la evidencia radiológica [35]: el plano sagital es la vista principal para la evaluación del LCA, donde el ligamento se visualiza en su totalidad como una estructura bandiforme entre el fémur y la tibia. El plano coronal

Cuadro 4.1: Pesos de fusión por plano para cada patología.

Patología	Sagital	Coronal	Axial
LCA	0,55	0,35	0,10
Menisco	0,30	0,55	0,15

proporciona información complementaria sobre la inserción tibial del ligamento. El plano axial ofrece una perspectiva transversal de utilidad limitada para el LCA pero relevante para otras estructuras. Para las lesiones meniscales, el plano coronal es el más informativo, ya que los meniscos se visualizan con mayor claridad en esta vista.

Esta estrategia de fusión presenta dos ventajas sobre la fusión en espacio de *logits*. En primer lugar, la predicción fusionada P_{LCA} es una probabilidad interpretable en el rango $[0, 1]$ que puede ser verificada manualmente por el radiólogo. En segundo lugar, los pesos son transparentes y modificables: un radiólogo con experiencia específica podría ajustar los pesos según su criterio clínico sin necesidad de reentrenar el modelo.

La comparación con configuraciones de pesos alternativas y el análisis de su impacto sobre el rendimiento se presentan en el Capítulo 5.

4.5.2 Función de pérdida

La Fase 2 se entrena con *Weighted Binary Cross-Entropy* (WBCE), una variante de la entropía cruzada binaria que pondera de forma diferente los falsos positivos y los falsos negativos:

$$\mathcal{L}_{WBCE} = -\frac{1}{N} \sum_{i=1}^N [w_i \cdot y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (4.6)$$

donde $w_i = pos_weight$ si $y_i = 1$ y $w_i = 1$ en caso contrario. Se usa $pos_weight = 2,0$, lo que significa que el modelo penaliza un falso negativo (lesión no detectada) el doble que un falso positivo (falsa alarma). Esta asimetría refleja directamente la prioridad clínica del sistema.

La elección de $pos_weight = 2,0$ responde a un compromiso. Se evaluaron distintos valores: con valores altos (por ejemplo, 3,5) el modelo tendía a sobreajustar, prediciendo siempre la clase positiva para minimizar la pérdida ponderada; con va-

lores bajos (1,5) la sensibilidad resultaba insuficiente. El valor de 2,0 representa el punto de equilibrio entre la penalización de los falsos negativos y la estabilidad del entrenamiento.

Se evaluó también *Focal Loss* para la Fase 2, pero empíricamente la WBCE produjo mejores resultados. Esto puede explicarse porque la etiqueta del LCA tiene un desbalance moderado (1:4), donde la ponderación directa de la BCE resulta más efectiva que la modulación adaptativa de *Focal Loss*, diseñada originalmente para desbalances más extremos en detección de objetos [34].

4.6 Regularización

El sobreajuste es un riesgo significativo cuando se entrenan 67 millones de parámetros (seis ResNet-18) con solo 800 ejemplos de entrenamiento por *fold*. Las cuatro estrategias empleadas se describen en las siguientes subsecciones.

4.6.1 Congelamiento de capas

En la Fase 2, se congelan los parámetros de las capas *layer1*, *layer2* y *layer3* de cada ResNet-18, entrenando únicamente *layer4* y la capa de clasificación *fc*, junto con los módulos de *attention pooling*. Esto reduce los parámetros entrenables de 33,5 millones a 25,2 millones por fase.

Las capas congeladas conservan los pesos de ImageNet, que proporcionan extractores de características de bajo y medio nivel (bordes, texturas, formas) transferibles entre dominios [23]. La capa *layer4* se entrena para adaptar las características de alto nivel al dominio específico de la RM musculoesquelética.

Se evaluó también el descongelamiento de *layer3*, que incrementa los parámetros entrenables a 31,5 millones. Sin embargo, esta configuración mostró un patrón de sobreajuste (la pérdida de entrenamiento descendía más rápido sin mejora en la de validación) y no aportó una mejora del rendimiento, por lo que se descartó. Esto sugiere que, con un conjunto de datos de 1 250 casos, la adaptación de una sola capa de alto nivel es preferible a una adaptación más profunda.

4.6.2 Dropout

Se aplica Dropout [32] con probabilidad 0,5 antes de la capa de clasificación de cada ResNet-18, desactivando aleatoriamente el 50 % de las neuronas durante el entrenamiento y forzando al modelo a aprender representaciones redundantes.

La introducción de Dropout fue motivada por la observación de un patrón claro de sobreajuste: la pérdida de entrenamiento descendía hasta valores cercanos a cero mientras que la pérdida de validación se estancaba.

4.6.3 Aumento de datos

Como se describió en el Capítulo 3, el aumento de datos aplicado durante el entrenamiento incluye rotaciones aleatorias ($\pm 8^\circ$), zoom ($\pm 10\%$), ajuste de brillo, ruido gaussiano, desenfoque gaussiano y corrección gamma.

4.6.4 Parada temprana y planificador de tasa de aprendizaje

El entrenamiento se detiene automáticamente cuando la pérdida de validación no mejora durante 7 épocas consecutivas (*patience* = 7), restaurando los pesos de la época con mejor pérdida de validación. Además, se emplea un planificador *ReduceLROnPlateau* que reduce la tasa de aprendizaje a la mitad cuando la pérdida de validación se estanca durante 3 épocas consecutivas:

$$LR_{nuevo} = LR_{actual} \times 0,5 \quad \text{si } \Delta \mathcal{L}_{val} < 0 \text{ durante 3 épocas} \quad (4.7)$$

Este esquema permite que el modelo continúe aprendiendo a un ritmo más lento cuando se aproxima a un mínimo local, en lugar de imponer una reducción predeterminada de la tasa de aprendizaje.

En la práctica, el entrenamiento se detiene típicamente entre las épocas 9 y 16, con una tasa de aprendizaje que desciende de 10^{-4} a $2,5 \times 10^{-5}$.

4.7 Optimización del umbral de decisión

La conversión de una probabilidad continua $P_{LCA} \in [0, 1]$ en una decisión binaria, es decir, en determinar si el caso presenta lesión del LCA (LCA+) o no la presenta (LCA−), requiere la selección de un umbral τ tal que:

$$\hat{y} = \begin{cases} \text{LCA+} & \text{si } P_{LCA} \geq \tau \\ \text{LCA-} & \text{si } P_{LCA} < \tau \end{cases} \quad (4.8)$$

La elección del umbral tiene un impacto directo en el balance entre sensibilidad y especificidad, y constituye una de las decisiones más relevantes del sistema desde el punto de vista clínico. Se calculan tres umbrales y se selecciona el clínico:

- **Óptimo para F1:** maximiza el F1-score sobre el conjunto de validación. Tiende a producir umbrales altos ($\sim 0,5-0,6$) que priorizan la precisión sobre la sensibilidad.
- **Youden:** maximiza el índice de Youden ($J = \text{Sens} + \text{Spec} - 1$), que representa el punto de la curva ROC más distante de la diagonal. Proporciona un balance estadístico entre sensibilidad y especificidad.
- **Clínico:** maximiza la especificidad sujeto a la restricción Sensibilidad $\geq 85\%$. Este es el umbral seleccionado para el sistema.

El umbral clínico se calcula sobre el conjunto de validación, y no sobre el de entrenamiento, donde las probabilidades predichas están más separadas y el modelo es más confiado. Calcularlo sobre el conjunto de entrenamiento produciría umbrales sobreajustados que no generalizan bien al conjunto de test, con caídas acusadas de la sensibilidad.

La priorización de la sensibilidad sobre la especificidad responde a la asimetría de las consecuencias de cada tipo de error en el contexto clínico. Un falso negativo (lesión del LCA no detectada) puede resultar en la ausencia de tratamiento, deterioro articular progresivo, inestabilidad crónica de la rodilla y, en casos severos, intervenciones quirúrgicas más complejas. Un falso positivo (sospecha de lesión no confirmada) resulta en una derivación a revisión por parte del radiólogo y, potencialmente, pruebas complementarias, con un coste significativamente menor que el de un falso negativo. Esta asimetría determina que el umbral clínico (sensibilidad $\geq 85\%$) sea la opción adecuada para un sistema de asistencia al diagnóstico, a pesar de producir una especificidad inferior a la que se obtendría con el umbral óptimo para F1.

4.8 Métricas de evaluación

Dado el marcado desbalance de la etiqueta del LCA (21,0 % de positivos), la exactitud global (*accuracy*) resulta una métrica engañosa: un clasificador que predijese siempre la clase mayoritaria alcanzaría en torno a un 79 % de aciertos sin detectar ninguna lesión. Por ello, la evaluación se basa en métricas más informativas para problemas desbalanceados y de orientación clínica. A partir de los recuentos de verdaderos positivos (VP), verdaderos negativos (VN), falsos positivos (FP) y falsos negativos (FN), se emplean las siguientes:

- **Sensibilidad** (tasa de verdaderos positivos, TPR): $VP / (VP + FN)$. Proporción de lesiones reales correctamente detectadas. Es la métrica prioritaria del sistema, dada la asimetría clínica que penaliza los falsos negativos.
- **Especificidad**: $VN / (VN + FP)$. Proporción de rodillas sanas correctamente identificadas. Su complementario, la tasa de falsos positivos ($FPR = 1 - \text{especificidad}$), constituye el eje horizontal de la curva ROC.
- **F1**: media armónica de la precisión y la sensibilidad. Resume en un único valor el equilibrio entre ambas, especialmente informativo para la clase minoritaria en problemas desbalanceados.
- **AUC**: área bajo la curva ROC [17], que enfrenta la sensibilidad a la tasa de falsos positivos para todos los umbrales posibles. Cuantifica la capacidad discriminativa del modelo con independencia del umbral de decisión, lo que la hace robusta frente al desbalance de clases y adecuada para comparar configuraciones.

La priorización de la sensibilidad, justificada en la Sección 4.7, orienta tanto la selección del umbral clínico como la interpretación de los resultados presentados en el Capítulo 5.

4.9 Procedimiento de entrenamiento

El sistema se evalúa mediante validación cruzada estratificada de 5 *folds* [12], donde la estratificación se realiza sobre la etiqueta del LCA para garantizar una distribución similar de positivos y negativos en cada *fold*. Los 1 250 casos se dividen en cada *fold* de la siguiente manera:

- **Entrenamiento:** 800 casos (64 %)
- **Validación:** 200 casos (16 %), seleccionados estratificadamente del conjunto de entrenamiento
- **Test:** 250 casos (20 %)

El conjunto de validación se utiliza para la parada temprana, la selección del umbral clínico y el planificador de la tasa de aprendizaje. El conjunto de test se emplea exclusivamente para la evaluación final y no influye en ninguna decisión de entrenamiento.

Las dos fases se entrenan de forma secuencial. Primero se entrena la Fase 1 hasta convergencia (típicamente 9–13 épocas). A continuación, se congelan los parámetros de la Fase 1 y se entrenan los modelos de la Fase 2 (típicamente 9–19 épocas). Este esquema secuencial evita la interferencia entre los objetivos de las dos fases y simplifica el proceso de entrenamiento.

El Cuadro 4.2 resume los hiperparámetros del sistema en su configuración final.

Para facilitar la reproducibilidad de los resultados, se fija la semilla aleatoria a 42 para la generación de los *folds* de validación cruzada y la inicialización de los pesos. No obstante, la naturaleza estocástica de las operaciones en GPU introduce una variabilidad residual entre ejecuciones con la misma configuración.

Cuadro 4.2: Hiperparámetros del sistema.

Componente	Parámetro	Valor
<i>Backbone</i>	Arquitectura	ResNet-18
	Parámetros totales	67,0M (6 modelos)
	Parámetros entrenables	25,2M (Fase 2)
Entrada	Resolución	224×224
	Cortes por volumen	32
	Canales	1 (escala de grises)
Entrenamiento	Optimizador	Adam [36]
	Tasa de aprendizaje	10^{-4}
	Tamaño de lote	2
	Épocas máximas	25
Regularización	Dropout	0,5
	Paciencia (parada)	7 épocas
	Paciencia (LR)	3 épocas
	Decaimiento de pesos	10^{-4}
Pérdida Fase 1	Tipo	<i>Focal Loss</i>
	α	0,25
	γ	2,0
Pérdida Fase 2	Tipo	WeightedBCE
	<i>pos_weight</i>	2,0
Umbral	Criterio	Sensibilidad $\geq 85\%$
	Fuente	Validación

Capítulo 5

Resultados

ESTE capítulo presenta la evaluación experimental del sistema en su configuración final, resultado de un proceso de diseño iterativo descrito en el Capítulo 4. La evaluación emplea las métricas definidas en la Sección 4.8 (sensibilidad, especificidad, F1 y AUC) y la estrategia de validación cruzada estratificada de 5 *folds* allí detallada.

La exposición sigue un hilo que parte de lo general y avanza hacia lo específico. En primer lugar se sintetiza la evolución del sistema durante su desarrollo, para situar la configuración final que se evalúa. A continuación se presenta su rendimiento global, a partir de los resultados de la validación cruzada y de la evaluación de la fase de triaje. Una vez establecido ese rendimiento, se profundiza en sus causas mediante el análisis de la contribución de cada plano anatómico y la validación estadística de las principales decisiones de diseño. Por último se examinan los aspectos orientados a la aplicación clínica del sistema, como su interpretabilidad, el análisis de errores, los reportes que genera, su eficiencia computacional y su aplicación a un caso clínico real. El capítulo se cierra con una síntesis de los resultados.

5.1 Evolución del sistema

El sistema final es el resultado de un proceso de desarrollo incremental en el que cada decisión de diseño se incorporó para corregir una limitación observada en la configuración anterior. El Cuadro 5.1 resume esta progresión en términos de AUC medio de validación cruzada.

Partiendo de una configuración base que agregaba los cortes mediante *max pooling* a baja resolución (AUC en torno a 0,758), el realce de contraste con CLAHE elevó

Cuadro 5.1: Evolución del AUC medio (validación cruzada de 5 *folds*) a través de las principales decisiones de diseño que afectan al poder discriminativo del sistema.

Configuración	AUC
Base (<i>max pooling</i> , 128×128)	0,758
+ CLAHE	0,793
+ <i>attention pooling</i>	0,819
+ Resolución 224×224 (final)	0,838

el AUC hasta 0,793; la sustitución del *max pooling* por *attention pooling* lo aumentó hasta 0,819; y el incremento progresivo de la resolución de entrada, hasta 224×224 píxeles, lo situó en el valor final de 0,838. Otras decisiones no perseguían incrementar el AUC, sino mejorar la sensibilidad y la robustez del sistema: la selección del umbral clínico desde el conjunto de validación se orientó a garantizar una sensibilidad mínima, y la incorporación de *Dropout* a mitigar el sobreajuste; su efecto sobre el AUC se mantiene dentro de la variabilidad entre ejecuciones (del orden de $\pm 0,01$). La contribución individual de las decisiones que sí impulsan el poder discriminativo se valida estadísticamente en la Sección 5.5.

5.2 Resultados de la validación cruzada

El sistema se evaluó mediante validación cruzada estratificada de 5 *folds* [12] sobre los 1 250 casos del conjunto de datos MRNet. El Cuadro 5.2 recoge las métricas obtenidas en cada *fold* para la detección de lesiones del LCA, junto con el umbral clínico seleccionado de forma independiente en cada uno.

El sistema alcanza un AUC medio de 0,838 con una sensibilidad del 84,7 % y una especificidad del 64,0 %. El AUC [17], métrica independiente del umbral de decisión, presenta una variabilidad reducida entre *folds* (desviación estándar de 0,022), lo que indica un comportamiento estable del modelo a lo largo de las distintas particiones. La sensibilidad media del 84,7 % se mantiene en línea con la prioridad clínica del sistema de minimizar los falsos negativos.

La variabilidad observada en la especificidad entre *folds* (del 46,0 % en el *fold* 1 al 73,2 % en el *fold* 3) refleja la sensibilidad del umbral clínico al conjunto de validación

Cuadro 5.2: Resultados de la validación cruzada de 5 *folds* para la detección de lesiones del LCA.

Fold	Sens (%)	Espec (%)	F1	AUC	Umbral
1	86,5	46,0	0,441	0,826	0,210
2	88,5	64,6	0,548	0,857	0,270
3	73,1	73,2	0,531	0,812	0,390
4	86,8	70,6	0,586	0,870	0,330
5	88,7	65,5	0,560	0,824	0,260
Media	84,7	64,0	0,533	0,838	0,292

de cada partición. Dado que el umbral se selecciona para garantizar una sensibilidad mínima del 85 % sobre un conjunto de validación reducido (42 casos positivos), pequeñas variaciones en la distribución de probabilidades predichas se traducen en umbrales diferentes y, en consecuencia, en distintos niveles de especificidad.

La Figura 5.1 presenta las curvas ROC de los cinco *folds* junto con la curva media que resume el comportamiento global del sistema. Las cinco curvas se mantienen próximas entre sí y claramente separadas de la diagonal de no discriminación, lo que confirma un poder discriminativo consistente a lo largo de las particiones y respalda la reducida desviación estándar del AUC señalada anteriormente. Sobre la curva media se resalta el punto operativo que fija el umbral clínico. Su ubicación en la zona de alta sensibilidad de la curva ilustra de forma gráfica el compromiso adoptado por el sistema, que prioriza la detección de lesiones (sensibilidad $\geq 85\%$) a costa de una especificidad más moderada, en coherencia con la asimetría clínica descrita en la Sección 4.7.

La Figura 5.2 muestra, en un panel independiente para cada uno de los cinco *folds*, las curvas de pérdida de entrenamiento y validación. Presentarlas por separado permite apreciar el comportamiento del entrenamiento en cada partición, donde se observa un patrón coherente entre todas ellas: la pérdida de entrenamiento descende de forma progresiva a lo largo de las épocas, indicando que el modelo aprende de los datos de forma efectiva. La pérdida de validación, en cambio, presenta una trayectoria irregular con picos pronunciados, comportamiento esperable dado el reducido tamaño del conjunto de validación (aproximadamente 42 casos positivos sobre un total de 200) y el desequilibrio de clases inherente al conjunto de datos [12]. La detención




Figura 5.1: Curvas ROC obtenidas en los cinco *folds* de la validación cruzada. La curva azul representa el comportamiento medio del sistema (AUC 0,838) y el punto destacado corresponde al punto operativo del umbral clínico seleccionado (sensibilidad $\geq$ 85 %).

temprana (*early stopping*) se activa, en la mayoría de los *folds*, entre las épocas 9 y 16, lo que refleja que el modelo alcanza rápidamente su punto óptimo en el conjunto de validación: continuar el entrenamiento más allá no reduciría la pérdida de validación sino que introduciría sobreajuste.

5.3 Evaluación de la fase de triaje

La Fase 1 del sistema, encargada de la detección de anomalías generales, se evaluó de forma independiente sobre los mismos *folds*. El Cuadro 5.3 recoge los resultados obtenidos.

La Fase 1 alcanza un AUC medio de 0,888, superior al de la Fase 2, lo que es esperable dado que la detección de anomalías generales es una tarea menos específica que la clasificación de lesiones del LCA. Esta fase cumple su doble función de tria-




Figura 5.2: Curvas de pérdida de entrenamiento (línea continua) y validación (línea discontinua) para cada uno de los cinco *folds* de la validación cruzada, en paneles independientes. Los marcadores verticales indican el punto de detención temprana de cada *fold*.

je e interpretabilidad: configurando un umbral de triaje conservador de 0,30, la Fase 1 alcanza una sensibilidad del 99,0 % para la detección de anomalías. Este punto de operación permitiría descartar en una etapa previa una pequeña fracción de los casos más claramente normales (en torno al 4,4 %), reduciendo la carga computacional de la clasificación específica.

5.4 Contribución de cada plano anatómico

Para analizar la contribución de cada plano anatómico y fundamentar la asignación de pesos, se evaluó el rendimiento del sistema utilizando cada plano de forma aislada y distintas combinaciones. El Cuadro 5.4 recoge los valores medios obteni-

Cuadro 5.3: Resultados de la Fase 1 (detección de anomalías) por *fold*.

Fold	Sens (%)	Espec (%)	AUC
1	88,2	74,5	0,895
2	83,7	70,8	0,900
3	76,7	87,5	0,889
4	82,4	82,6	0,915
5	74,6	84,4	0,842
Media	81,1	80,0	0,888

dos en la validación cruzada de 5 *folds*. Las filas combinadas emplean el esquema de fusión ponderada del sistema: la combinación sagital+coronal con pesos 0,6 y 0,4, la sagital+axial con 0,85 y 0,15, y la configuración completa con 0,55 (sagital), 0,35 (coronal) y 0,10 (axial). Los valores de sensibilidad y especificidad se calculan al umbral clínico, por lo que el AUC, independiente del umbral, es la métrica más adecuada para la comparación.

Cuadro 5.4: Ablación por plano anatómico para la detección de lesiones del LCA (valores medios de la validación cruzada de 5 *folds*). Las columnas Sens y Espec se calculan al umbral clínico.

Configuración	Sens (%)	Espec (%)	F1	AUC
Solo sagital	77,1	72,5	0,558	0,830
Solo coronal	64,8	57,5	0,396	0,643
Solo axial	72,1	63,1	0,473	0,743
Sagital + coronal	83,6	64,4	0,531	0,831
Sagital + axial	78,7	71,4	0,560	0,829
Completo (S+C+A)	84,7	64,0	0,533	0,838

Entre los planos individuales, el sagital es el más informativo para la detección del LCA, con un AUC medio de 0,830, por delante del axial (0,743) y del coronal (0,643), este último el menos discriminativo de forma aislada. Este orden respalda que el plano sagital reciba el mayor peso de fusión (0,55), en consonancia con que el ligamento

cruzado anterior se visualiza en su trayecto completo en esta vista.

La combinación de planos mejora el rendimiento respecto a cualquier vista aislada. Añadir un segundo plano al sagital incrementa de forma apreciable la sensibilidad, que alcanza el 83,6 % en la configuración sagital+coronal, manteniendo un AUC comparable; y la fusión de los tres planos obtiene los mejores valores de toda la tabla, con un AUC medio de 0,838 y una sensibilidad del 84,7 %. Dado que la sensibilidad es la métrica prioritaria del sistema, este resultado justifica empíricamente la decisión de fusionar las tres vistas en lugar de basar la detección en el plano sagital por sí solo.

Merece una mención el papel del plano coronal. Pese a ser el menos informativo de forma aislada para el LCA, recibe en la fusión un peso (0,35) superior al del axial (0,10). Esta asignación responde a dos motivos. Por un lado, su aportación en combinación es positiva: la fusión sagital+coronal, en la que el coronal recibe un peso considerable (0,4), iguala en AUC a la sagital+axial y proporciona la mayor sensibilidad entre las configuraciones de dos planos. Por otro, las tres ramas comparten arquitectura con la detección de lesiones meniscales, tarea para la cual el plano coronal es la vista más informativa, por lo que su contribución resulta imprescindible para el sistema en su conjunto.

La fusión completa sacrifica algo de especificidad (64,0 %) y de F1 frente a las configuraciones con mayor peso del sagital o del axial, que alcanzan especificidades en torno al 72 %. Este compromiso es coherente con la prioridad clínica del sistema, que antepone la detección de lesiones a la reducción de falsas alarmas. En conjunto, la ablación respalda tanto la estrategia de fusión ponderada como el orden de magnitud de los pesos asignados a cada plano.

5.5 Análisis estadístico

Se realizó un análisis estadístico para cuantificar la incertidumbre de las métricas y validar el impacto de las principales decisiones de diseño.

5.5.1 Intervalos de confianza

El Cuadro 5.5 recoge los intervalos de confianza al 95 % de las métricas principales, calculados a partir de los resultados de los cinco *folds*.

El intervalo de confianza del AUC, relativamente estrecho ([0,811; 0,865]), refuerza

Cuadro 5.5: Intervalos de confianza al 95 % de las métricas principales.

Métrica	Media	IC 95 %
Sensibilidad	84,7 %	[77,4 %; 92,0 %]
Especificidad	64,0 %	[52,1 %; 75,8 %]
F1-Score	0,533	[0,472; 0,594]
AUC	0,838	[0,811; 0,865]

la robustez del rendimiento discriminativo del sistema.

5.5.2 Validación del impacto de CLAHE

Para cuantificar la contribución de CLAHE [27] se comparó una versión temprana del sistema sin esta técnica de preprocesamiento (AUC 0,758) con la configuración final que la incorpora (AUC 0,838). Conviene precisar que ambas versiones difieren también en otras mejoras introducidas durante el desarrollo iterativo (en particular el mecanismo de *attention pooling* y el aumento de la resolución espacial), por lo que esta comparación refleja el efecto acumulado de dichos cambios respecto a la línea base previa a CLAHE. El incremento atribuible de forma aislada a CLAHE, evaluado entre dos versiones consecutivas que únicamente difieren en su aplicación, es de 0,758 a 0,793. Un test t pareado sobre los cinco *folds* entre la versión base y la final confirma que la mejora es estadísticamente significativa ($t = 6,567$, $p = 0,003$), con un tamaño del efecto de Cohen muy elevado ($d = 2,94$; por convención, un valor $d > 0,8$ se considera un efecto grande) [18]. Este resultado valida empíricamente la decisión de incorporar CLAHE al flujo de preprocesamiento.

5.5.3 Impacto del *attention pooling*

De forma análoga, se comparó el *attention pooling* [28] con el *max pooling* [7] empleado en la versión base. Al igual que en el caso de CLAHE, esta comparación entre la versión base (AUC 0,793) y la configuración final (0,838) incorpora también el aumento posterior de la resolución; el incremento atribuible de forma aislada al *attention pooling* es de 0,793 a 0,819. El test t pareado sobre los cinco *folds* entre ambas versiones arroja un tamaño del efecto grande ($d = 1,19$), si bien la mejora no

alcanza significancia estadística ($t = 2,659$, $p = 0,056$). Conviene señalar que, con únicamente cinco *folds*, la potencia estadística es limitada: un resultado no significativo no implica ausencia de efecto, sino insuficiencia de datos para demostrarlo con el nivel de confianza establecido. El elevado tamaño del efecto y la ventaja añadida en interpretabilidad justifican la adopción del *attention pooling*.

5.5.4 Impacto del aumento de datos

Para cuantificar el impacto del aumento de datos, se realizó un estudio de ablación sobre el primer *fold* de la validación cruzada. Se entrenaron dos modelos idénticos en arquitectura e hiperparámetros, uno con aumento de datos activado y otro sin él, y se evaluaron sobre el mismo conjunto de test. El Cuadro 5.6 recoge los resultados.

Cuadro 5.6: Ablación del aumento de datos (*fold* 1). Sens: sensibilidad; Espec: especificidad; F1: puntuación F1; AUC: área bajo la curva ROC.

Condición	Sens (%)	Espec (%)	F1	AUC
Sin aumento de datos	82,7	47,0	0,430	0,743
Con aumento de datos	80,8	65,2	0,515	0,807

La incorporación del aumento de datos mejora la especificidad en 18,2 puntos porcentuales y el AUC en 0,064, con una reducción marginal de la sensibilidad de 1,9 puntos, lo que apoya su función como mecanismo de regularización.

5.6 Interpretabilidad

La interpretabilidad de los modelos de aprendizaje profundo es un requisito fundamental para su adopción clínica [13], ya que el personal de radiología necesita comprender qué regiones y cortes del estudio de RM sustentan la predicción del sistema para poder validarla con su propio criterio diagnóstico. Esta sección presenta dos aspectos complementarios de la interpretabilidad del sistema: la selección del corte sobre el que se aplica GradCAM++ [30] mediante el mapa de atención del módulo de *attention pooling* [28], y los mapas de activación resultantes.

5.6.1 Discrepancia entre el corte de atención y el corte central

Una de las contribuciones del trabajo es la aplicación de GradCAM++ [30] sobre el corte que el modelo realmente utiliza para su predicción, en lugar del corte geométricamente central. Para cuantificar la relevancia de esta decisión, se analizó la distancia entre el corte de máxima atención y el corte central del volumen. El Cuadro 5.7 recoge los resultados.

Cuadro 5.7: Distancia entre el corte de máxima atención y el corte central.

Plano	Offset medio	Offset máximo	% $\neq$ centro
Sagital	7,0	14	99,2 %
Coronal	9,7	16	99,2 %
Axial	7,5	16	96,8 %

En el 99,2 % de los casos, el corte que determina la predicción del modelo en el plano sagital difiere del corte central, con una distancia media de 7 cortes. Este resultado demuestra empíricamente que la práctica habitual de aplicar GradCAM [29] sobre el corte central no refleja la decisión real del modelo, y valida la decisión de emplear el corte de máxima atención para una interpretabilidad fiel.

5.6.2 Mapas de activación

La Figura 5.3 muestra los mapas de GradCAM++ generados sobre el corte de máxima atención para un caso del conjunto de test correctamente clasificado. En cada plano se visualiza tanto el corte original en escala de grises como el mapa de activación superpuesto. Las regiones de mayor activación se concentran en la zona intercondílea, donde se localiza el ligamento cruzado anterior, lo que indica que el modelo fundamenta su predicción en la región anatómicamente relevante y no en artefactos periféricos del volumen.

5.7 Análisis de errores

El análisis de los casos mal clasificados aporta información sobre el comportamiento del sistema. Sobre el mejor *fold*, el sistema produjo 7 falsos negativos y 58




Figura 5.3: Mapas de GradCAM++ sobre el corte de máxima atención de cada plano anatómico para un caso del conjunto de test. Columna izquierda: corte original en escala de grises. Columna derecha: mapa de activación superpuesto. Las regiones cálidas (amarillo-rojo) indican las zonas que más contribuyen a la predicción del modelo.

falsos positivos.

En cuanto a los falsos negativos (lesiones no detectadas), su probabilidad media predicha fue del 21,5 %, cercana al umbral de decisión. De los 7 casos, 6 presentaban una probabilidad superior al 15 %, situándose próximos al umbral, y únicamente 1 caso recibió una probabilidad muy baja (6,3 %), indicando un error en el que el modelo estaba seguro. Esto sugiere que la mayoría de los falsos negativos son casos límite, no fallos graves del sistema.

Respecto a los falsos positivos (falsas alarmas), su probabilidad media fue del 53,0 %. De los 58 casos, 33 presentaban probabilidades inferiores al 50 %, próximas al umbral. El análisis por plano de estos casos revela con frecuencia discrepancias entre vistas (por ejemplo, una probabilidad sagital elevada frente a una coronal baja), lo que sugiere que parte de los falsos positivos proceden de hallazgos visibles en un solo plano que el sistema de fusión amplifica. Dada la prioridad clínica del sistema,

un falso positivo, que conduce a una revisión adicional por parte del radiólogo, tiene consecuencias mucho menos graves que un falso negativo.

5.8 Reportes clínicos

El sistema genera reportes clínicos estructurados que integran las dos fases. Cada reporte incluye el resultado del triaje (Fase 1), la probabilidad de lesión del LCA con su nivel de sospecha (Fase 2), el análisis desglosado por plano con el corte más relevante de cada vista, y una medida de concordancia entre planos. Esta estructura está orientada a facilitar la integración del sistema en un flujo de trabajo clínico, proporcionando al personal de radiología no solo una predicción sino también el contexto que la fundamenta.

Los niveles de sospecha se definen en función de la probabilidad predicha: muy bajo, bajo, moderado, alto o muy alto. El reporte incluye además una advertencia explícita de que el sistema es una herramienta de asistencia que no sustituye el criterio del personal de radiología.

En la Figura 5.5 se ve cómo sería un ejemplo de un reporte clínico generado por el sistema.

5.9 Eficiencia computacional

El entrenamiento completo del sistema (cinco *folds*, ambas fases) requiere aproximadamente 8 horas y 40 minutos en una GPU Tesla T4. La inferencia sobre un caso individual se realiza en 0,08 segundos, un tiempo que no supondría una limitación para su integración en un flujo de trabajo clínico. El consumo energético estimado por ejecución completa es de 0,61 kWh (Tesla T4 a 70 W durante 8,65 horas).

5.10 Caso de estudio: aplicación a un caso clínico real

La validación cualitativa del sistema se realizó sobre una resonancia magnética de rodilla propia del autor, procedente de un centro hospitalario distinto al del conjunto de datos MRNet. Tras una lesión sufrida durante la práctica deportiva, se realizó una primera RM cuyo informe radiológico indicaba únicamente una rotura parcial del ligamento cruzado anterior. Siete meses después, al repetir la resonancia para evaluar la

evolución, se confirmó que también existía una lesión del menisco externo que había pasado completamente desapercibida en el análisis inicial. Esta experiencia personal, descrita con más detalle en la motivación del Capítulo 1, es la que originó el interés por desarrollar este proyecto.

La adquisición se realizó con una secuencia potenciada en densidad protónica con supresión grasa (PD-FS, del inglés *proton density fat-suppressed*). Se trata de una secuencia de uso habitual en resonancia musculoesquelética y especialmente sensible a las lesiones de meniscos, ligamentos y cartílago, ya que la supresión de la señal de la grasa realza el contraste de las estructuras con alto contenido en agua y de las zonas de edema. Esta secuencia es distinta de las empleadas en el conjunto de entrenamiento, lo que introduce una diferencia de dominio que pone a prueba la capacidad de generalización del sistema. Aplicar el sistema sobre este caso permite evaluar si el modelo es capaz de detectar lesiones reales en condiciones de adquisición distintas a las del entrenamiento.

El Cuadro 5.8 recoge los resultados del sistema sobre este caso, empleando el modelo del mejor *fold*.

Cuadro 5.8: Resultados del sistema sobre el caso clínico personal.

Evaluación	Probabilidad	Predicción
Anomalía general (Fase 1)	0,651	Anomalía detectada
Lesión del LCA (Fase 2)	0,847	Sospecha de lesión
Lesión meniscal (Fase 2)	0,816	Sospecha de lesión

El sistema detectó correctamente ambas lesiones. Especialmente significativa resulta la detección de la lesión meniscal (probabilidad 0,816): es precisamente la lesión que los radiólogos pasaron por alto en el primer informe, y que condicionó el proceso de recuperación del paciente durante siete meses. El análisis por plano para el LCA mostró una probabilidad del 0,998 en el plano sagital, coherente con la localización anatómica esperada; los planos axial (0,896) y coronal (0,596) contribuyeron en menor medida, en línea con los pesos de fusión asignados.

Cabe señalar que en el plano coronal el corte de máxima atención se situó en el primer corte del volumen, lo que sugiere una posible influencia del rellenado de bordes en este plano. Esta limitación no afectó al resultado final gracias al bajo peso asignado al plano coronal en la fusión para el LCA (0,35).

La Figura 5.4 muestra los mapas de GradCAM++ generados sobre el corte de máxima atención de cada plano para este caso clínico. En el plano sagital, las activaciones se concentran en la región intercondílea medial, zona anatómica donde se insertan las fibras del ligamento cruzado anterior, coherente con una probabilidad de 0,998. El plano axial exhibe igualmente activaciones en la región central de la articulación. Este patrón de activación, obtenido sobre una secuencia PD-FS procedente de un centro externo, sugiere una capacidad de generalización del sistema más allá del dominio de entrenamiento.




Figura 5.4: Mapas de GradCAM++ sobre el corte de máxima atención de cada plano para el caso clínico personal (secuencia PD con supresión grasa, centro externo). Las regiones cálidas indican las zonas anatómicas que sustentan la predicción del sistema. La activación en la región intercondílea del plano sagital es coherente con la localización del LCA.

Este resultado, aunque corresponde a un único caso y debe interpretarse con la debida cautela, ilustra el potencial del sistema como herramienta de apoyo: un modelo entrenado con datos de un único centro y protocolo de adquisición fue capaz de señalar ambas patologías en un estudio de dominio distinto, incluida la lesión que no había sido identificada inicialmente.

La Figura 5.5 reproduce el reporte generado para el caso personal, tal y como se

presentaría al radiólogo: incluye el resultado del triaje, las probabilidades por patología con su nivel de sospecha, el desglose por plano anatómico y las advertencias relevantes sobre la fiabilidad de los cortes de atención.

INFORME DEL SISTEMA DE APOYO AL DIAGNÓSTICO

Datos de adquisición

Centro: Hospital externo (fuera del dominio MRNet)

Secuencia: PD con supresión grasa (PD-FS)

Fase 1 · Triage

Probabilidad de anomalía: **0,651**

Resultado: **anomalía detectada** (umbral 0,30)

Fase 2 · Clasificación

Lesión del ligamento cruzado anterior

Probabilidad fusionada: **0,847** → **sospecha alta**

Por plano: sagital 0,998 · coronal 0,596 · axial 0,896

Concordancia entre planos: alta (2 de 3 planos > 0,80)

Lesión meniscal

Probabilidad fusionada: **0,816** → **sospecha alta**

[!] Plano coronal: el corte de máxima atención se sitúa en el borde del volumen; interpretar con cautela (posible artefacto de relleno).

Aviso: informe de apoyo al diagnóstico; no sustituye el criterio clínico del radiólogo.

Figura 5.5: Reporte clínico generado por el sistema para el caso clínico personal. Integra el resultado del triaje (Fase 1), la probabilidad de lesión por patología con su nivel de sospecha (Fase 2), el desglose por plano anatómico y las advertencias sobre cortes de atención en el borde del volumen.

5.11 Síntesis de resultados

Los experimentos presentados en este capítulo permiten esbozar una valoración global del comportamiento del sistema. En la detección de lesiones del LCA, la confi-

guración final alcanza un AUC medio de 0,838 (IC 95 % [0,811; 0,865]) con una sensibilidad del 84,7 %, en línea con la prioridad clínica de minimizar los falsos negativos; la reducida variabilidad entre particiones apunta a un comportamiento estable del modelo a lo largo de la validación cruzada. La fase de triaje, con un AUC de 0,888, complementa esta tarea como filtro inicial.

El análisis por componentes ayuda a interpretar este resultado. El preprocesamiento con CLAHE es la decisión con mayor respaldo estadístico, mientras que el *attention pooling*, pese a no alcanzar significancia con el número de particiones disponible, muestra un efecto grande y aporta interpretabilidad. La ablación por planos respalda la estrategia de fusión ponderada, con el plano sagital como vista más informativa para el LCA. El análisis de errores sugiere que la mayoría de los falsos negativos corresponden a casos próximos al umbral de decisión, más que a fallos rotundos del modelo, y el coste computacional de la inferencia es reducido.

Estos resultados deben interpretarse teniendo en cuenta las limitaciones del estudio, en particular el uso de un único conjunto de datos y la potencia estadística asociada a cinco particiones, que se discuten de forma integrada, junto con las aportaciones del trabajo, en el Capítulo 6.

Capítulo 6

Conclusiones

ESTE capítulo sintetiza las principales aportaciones del trabajo, evalúa el grado de cumplimiento de los objetivos planteados, discute las limitaciones identificadas y propone líneas de investigación futura.

6.1 Aportaciones del trabajo

Este trabajo presenta un sistema de detección automática de lesiones del ligamento cruzado anterior en resonancia magnética de rodilla basado en aprendizaje profundo. Las aportaciones se agrupan en cuatro ámbitos.

En el ámbito del **rendimiento predictivo**, el sistema alcanza un AUC medio de 0,838 con una sensibilidad del 84,7 % en validación cruzada estratificada de 5 *folds* [12] sobre los 1 250 casos del conjunto de datos MRNet, con un comportamiento estable entre particiones. La fase de triaje complementa la detección como filtro inicial, capaz de descartar con seguridad los casos más claramente normales antes de la clasificación específica.

En el ámbito del **preprocesamiento**, la incorporación de CLAHE [27] es la decisión de diseño con mayor respaldo estadístico del trabajo. Su efecto sobre el rendimiento se validó mediante un test pareado sobre los cinco *folds*, resultando estadísticamente significativo ($p = 0,003$) y con un tamaño del efecto muy elevado [18]. Conviene matizar que parte de esa mejora se solapa con el resto de avances del desarrollo iterativo, por lo que el efecto aislado de CLAHE es más moderado, si bien sigue constituyendo una contribución consistente.

En el ámbito de la **arquitectura**, la sustitución del *max pooling* [7] por *attention*

pooling [28] sobre los cortes del volumen mejora la capacidad discriminativa del sistema con un efecto grande, aunque sin alcanzar significancia estadística debido a la potencia limitada de cinco *folds*. Más allá de la métrica, este módulo aporta un mapa de relevancia por corte que funciona como herramienta de interpretabilidad. La estrategia de fusión ponderada por plano, por su parte, quedó respaldada por el estudio de ablación: el plano sagital es el más informativo de forma aislada, pero la combinación de los tres planos ofrece el mejor rendimiento global, lo que confirma el valor de integrar las distintas vistas.

En el ámbito de la **interpretabilidad**, la principal aportación es un método de explicación fiel a la decisión del modelo: en lugar de aplicar GradCAM++ sobre el corte geoméricamente central del volumen, como suele hacerse, se aplica sobre el corte que el módulo de atención señala como más relevante. El análisis confirma que ese corte rara vez coincide con el central, por lo que la práctica habitual ofrecería una explicación ajena a la información en la que el modelo fundamenta realmente su predicción. Como validación cualitativa fuera del dominio de entrenamiento, el sistema detectó además ambas lesiones presentes en un caso clínico real (rotura parcial del LCA y lesión meniscal), incluida la lesión meniscal que no había sido identificada en el informe radiológico inicial.

6.2 Cumplimiento de objetivos

Los cinco objetivos específicos planteados en el Capítulo 1 se han cumplido en los términos siguientes.

El primero, relativo al análisis del conjunto de datos, se abordó mediante un estudio exploratorio documentado en el Capítulo 3, que reveló el marcado desbalanceo de la etiqueta del LCA (21,0 % de positivos, ratio 1:4) y la variabilidad en el número de cortes por plano, justificando las decisiones de preprocesamiento adoptadas.

El segundo, relativo al diseño e implementación del sistema, se materializó en el sistema descrito en el Capítulo 4, que integra dos fases secuenciales, seis modelos ResNet-18 [22] con *attention pooling* y fusión ponderada en espacio de probabilidades con pesos anatómicamente fundamentados.

El tercero, sobre el impacto de las estrategias de preprocesamiento y diseño arquitectónico, se abordó mediante estudios de ablación cuantitativos para CLAHE, *attention pooling*, resolución espacial, aumento de datos y ablación por plano, con análisis

de significancia estadística y tamaño del efecto donde el número de muestras lo permitía.

El cuarto, relativo a la evaluación experimental, se desarrolló mediante validación cruzada estratificada de 5 *folds* [12] con cálculo de intervalos de confianza al 95 %, lo que proporciona una estimación más robusta del rendimiento frente a las particiones fijas de 120 casos empleadas en trabajos previos [7, 10].

El quinto, sobre la interpretabilidad, se abordó mediante la integración de Grad-CAM++ [30] sobre los cortes de máxima atención, el análisis cuantitativo de la discrepancia entre el corte de atención y el corte central, y la generación de reportes clínicos estructurados con niveles de sospecha y análisis desglosado por plano.

6.3 Limitaciones

Los resultados obtenidos deben interpretarse dentro del contexto de las siguientes limitaciones, cuyo reconocimiento explícito es parte de una evaluación científicamente honesta del sistema.

La limitación más relevante desde el punto de vista de la validación externa es la **dependencia de un único conjunto de datos** procedente de un único centro hospitalario (Stanford University Medical Center) y un único protocolo de adquisición. Los estudios de RM presentan una variabilidad considerable entre centros en cuanto a equipamiento, parámetros de adquisición y características de contraste. La capacidad del sistema para generalizar a otros entornos hospitalarios está respaldada de forma cualitativa por el resultado del caso clínico personal, adquirido con secuencia PD con supresión grasa en un centro distinto, pero no ha sido validada de forma sistemática.

La segunda limitación es la **potencia estadística reducida** derivada de la disponibilidad de únicamente cinco *folds* en la validación cruzada. Esta limitación impide establecer con significancia estadística la superioridad del *attention pooling* sobre el *max pooling* ($p = 0,056$) a pesar de un tamaño del efecto grande, y hace que las comparativas de ablación sobre configuraciones individuales sean indicativas en lugar de concluyentes.

La tercera limitación es la **ausencia de comparativa directa con lectores humanos** sobre el mismo conjunto de test. Las métricas absolutas reportadas (sensibilidad 84,7 %, especificidad 64,0 %) no permiten cuantificar el beneficio clínico real respecto a la práctica radiológica estándar sin un estudio de comparación directa so-

bre los mismos casos.

La cuarta limitación es la **granularidad binaria de las etiquetas**: el sistema detecta la presencia o ausencia de lesión del LCA, pero no distingue entre rotura parcial y completa, ni gradúa la extensión de la lesión. Esta distinción es clínicamente relevante para la toma de decisiones terapéuticas.

Finalmente, en el plano de la interpretabilidad, el corte de máxima atención del plano coronal en el caso clínico personal se situó en el primer corte del volumen, lo que sugiere una posible influencia del rellenado de bordes (*edge padding*) en este plano. Este fenómeno no ha sido analizado de forma sistemática sobre el conjunto de test y constituye una limitación del módulo de atención a tener en cuenta en aplicaciones clínicas.

6.4 Líneas futuras de investigación

Las limitaciones identificadas apuntan a las siguientes líneas de trabajo que podrían ampliar el alcance y la solidez del sistema.

- **Validación multicéntrica.** Constituye el paso más relevante para evaluar la capacidad de generalización del sistema. Un estudio sobre datos procedentes de centros con distintos equipos y protocolos de adquisición permitiría cuantificar la degradación del rendimiento debida al cambio de dominio y orientar estrategias de adaptación, como el ajuste fino con un subconjunto de datos del centro destino.
- **Comparativa directa con radiólogos.** Evaluar el sistema frente a especialistas sobre el mismo conjunto de test proporcionaría una medida clínicamente significativa de su valor añadido y permitiría cuantificar si actuaría como una segunda lectura efectiva en la práctica.
- **Arquitecturas volumétricas nativas.** Las redes convolucionales tridimensionales o los transformadores de visión adaptados al procesamiento volumétrico podrían capturar la continuidad espacial de la lesión en las tres dimensiones sin discretizar el volumen en cortes independientes, eliminando la necesidad del módulo de agregación.
- **Clasificación de gravedad.** Distinguir el grado de la lesión (rotura parcial

frente a completa, grado de afectación meniscal) representaría una extensión natural del sistema con mayor utilidad clínica directa, dado que esa distinción condiciona el planteamiento terapéutico.

- **Cuantificación de incertidumbre.** Estimar la confianza del sistema en cada predicción, mediante técnicas como *MC-Dropout* [37] o predicción conformal, enriquecería los reportes clínicos. De los 7 falsos negativos del mejor *fold*, solo 1 recibió una probabilidad muy baja (6,3 %), lo que sugiere que la mayoría son casos límite en los que una señal de baja confianza podría alertar al radiólogo.
- **Extensión a otras patologías de rodilla.** Incorporar otras patologías documentadas en el conjunto de datos MRNet, como las lesiones del ligamento cruzado posterior o las alteraciones osteocondrales, ampliaría el alcance diagnóstico sin modificar la arquitectura fundamental del sistema, diseñada para añadir nuevas tareas de clasificación en la Fase 2 de forma modular.

Bibliografía

- [1] T. L. Sanders, H. M. Kremers, A. J. Bryan *et al.*, “Incidence of anterior cruciate ligament tears and reconstruction: A 21-year population-based study,” *The American Journal of Sports Medicine*, vol. 44, no. 6, pp. 1502–1507, 2016.
- [2] N. Phelan, P. Rowland, R. Galvin, and J. M. O’Byrne, “A systematic review and meta-analysis of the diagnostic accuracy of MRI for suspected ACL and meniscal tears of the knee,” *Knee Surgery, Sports Traumatology, Arthroscopy*, vol. 24, no. 5, pp. 1525–1539, 2016.
- [3] R. Crawford, G. Walley, S. Bridgman, and N. Maffulli, “Magnetic resonance imaging versus arthroscopy in the diagnosis of knee pathology, concentrating on meniscal lesions and ACL tears: a systematic review,” *British Medical Bulletin*, vol. 84, pp. 5–23, 2007.
- [4] E. A. Krupinski, K. S. Berbaum, R. T. Caldwell, K. M. Schartz, and J. Kim, “Long radiology workdays reduce detection and accommodation accuracy,” *Journal of the American College of Radiology*, vol. 7, no. 9, pp. 698–704, 2010.
- [5] A. Esteva, B. Kuprel, R. A. Novoa, J. Ko, S. M. Swetter, H. M. Blau, and S. Thrun, “Dermatologist-level classification of skin cancer with deep neural networks,” *Nature*, vol. 542, no. 7639, pp. 115–118, 2017.
- [6] G. Litjens, T. Kooi, B. E. Bejnordi *et al.*, “A survey on deep learning in medical image analysis,” *Medical Image Analysis*, vol. 42, pp. 60–88, 2017.
- [7] N. Bien, P. Rajpurkar, R. L. Ball *et al.*, “Deep-learning-assisted diagnosis for knee magnetic resonance imaging: Development and retrospective validation of MR-Net,” *PLOS Medicine*, vol. 15, no. 11, p. e1002699, 2018.

- [8] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems (NIPS)*, vol. 25, 2012, pp. 1097–1105.
- [9] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “ImageNet: A large-scale hierarchical image database,” in *2009 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2009, pp. 248–255.
- [10] D. Azcona, K. McGuinness, and A. F. Smeaton, “A comparative study of existing and new deep learning methods for detecting knee injuries using the MRNet dataset,” in *2020 International Conference on Intelligent Data Science Technologies and Applications (IDSTA)*, 2020, pp. 149–155.
- [11] A. Panteli *et al.*, “Detection and classification of knee injuries from MR images using the MRNet dataset with progressively operating deep learning methods,” *Machine Learning and Knowledge Extraction*, vol. 3, no. 4, pp. 1001–1014, 2021.
- [12] R. Kohavi, “A study of cross-validation and bootstrap for accuracy estimation and model selection,” *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI)*, vol. 14, no. 2, pp. 1137–1145, 1995.
- [13] A. Singh, S. Sengupta, and V. Lakshminarayanan, “Explainable deep learning models in medical image analysis,” *Journal of Imaging*, vol. 6, no. 6, p. 52, 2020.
- [14] Manfred, “Guía salarial 2026: Salarios en tecnología en España,” 2026. [En línea]. Disponible en: <https://www.getmanfred.com/blog/guia-salarial-2026-salarios-en-tecnologia-espana-manfred>
- [15] A. Paszke, S. Gross, F. Massa *et al.*, “PyTorch: An imperative style, high-performance deep learning library,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019, pp. 8024–8035.
- [16] G. Bradski, “The OpenCV library,” *Dr. Dobb’s Journal of Software Tools*, vol. 25, no. 11, pp. 120–125, 2000.
- [17] T. Fawcett, “An introduction to ROC analysis,” *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.

- [18] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. Lawrence Erlbaum Associates, 1988.
- [19] V. Gulshan, L. Peng, M. Coram, M. C. Stumpe *et al.*, “Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs,” *JAMA*, vol. 316, no. 22, pp. 2402–2410, 2016.
- [20] P. Chea and J. C. Mandell, “Current applications and future directions of deep learning in musculoskeletal radiology,” *Skeletal Radiology*, vol. 49, no. 2, pp. 183–197, 2020.
- [21] A. Siouras, S. Moustakidis, A. Giannakidis, G. Chalatsis, I. Liampas, M. Vlychou, M. Hantes, S. Tasoulis, and D. Tsaopoulos, “Knee injury detection using deep learning on MRI studies: A systematic review,” *Diagnostics*, vol. 12, no. 2, p. 537, 2022.
- [22] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [23] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, “How transferable are features in deep neural networks?” in *Advances in Neural Information Processing Systems (NIPS)*, vol. 27, 2014, pp. 3320–3328.
- [24] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” *arXiv preprint arXiv:1409.1556*, 2015.
- [25] C.-H. Tsai, N. Kiryati, E. Konen, I. Eshed, and A. Mayer, “Knee injury detection using MRI with efficiently-layered network (ELNet),” in *Proceedings of the Third Conference on Medical Imaging with Deep Learning (MIDL)*, ser. Proceedings of Machine Learning Research, vol. 121, 2020, pp. 784–794.
- [26] Y. Wang *et al.*, “Artificial intelligence-assisted accurate diagnosis of anterior cruciate ligament tears using customized CNN and YOLOv9,” *Diagnostics*, vol. 15, no. 2, p. 198, 2025.
- [27] S. M. Pizer, E. P. Amburn, J. D. Austin *et al.*, “Adaptive histogram equalization and its variations,” *Computer Vision, Graphics, and Image Processing*, vol. 39, no. 3, pp. 355–368, 1987.

- [28] M. Ilse, J. M. Tomczak, and M. Welling, “Attention-based deep multiple instance learning,” in *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 2018, pp. 2127–2136.
- [29] R. R. Selvaraju, M. Cogswell, A. Das *et al.*, “Grad-CAM: Visual explanations from deep networks via gradient-based localization,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 618–626.
- [30] A. Chattopadhyay, A. Sarkar, P. Howlader, and V. N. Balasubramanian, “Grad-CAM++: Generalized gradient-based visual explanations for deep convolutional networks,” in *2018 IEEE Winter Conference on Applications of Computer Vision (WACV)*, 2018, pp. 839–847.
- [31] C. Shorten and T. M. Khoshgoftaar, “A survey on image data augmentation for deep learning,” *Journal of Big Data*, vol. 6, no. 1, p. 60, 2019.
- [32] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929–1958, 2014.
- [33] M. Tan and Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, vol. 97. PMLR, 2019, pp. 6105–6114.
- [34] T.-Y. Lin, P. Goyal, R. Girshick *et al.*, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.
- [35] A. M. Naraghi and L. M. White, “Imaging of athletic injuries of knee ligaments and menisci: Sports imaging series,” *Radiology*, vol. 281, no. 1, pp. 23–40, 2016.
- [36] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *3rd International Conference on Learning Representations (ICLR)*, 2015.
- [37] Y. Gal and Z. Ghahramani, “Dropout as a Bayesian approximation: Representing model uncertainty in deep learning,” in *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, vol. 48, 2016, pp. 1050–1059.